Análise Comparativa de Redes Neurais Artificias em um Sistema de Orquestração Procedural de Conteúdo Adaptada a Usuários em Tempo Real

Pedro G. Gonçalves

Instituto de Geociências e Ciências Exatas – Universidade Estadual Paulista (UNESP)
Rio Claro – SP – Brazil

pedro.g.goncalves@unesp.br

Abstract. *One of the challenges in the digital games industry is understanding user preferences in order to provide experiences that maintain high levels of immersion and satisfaction. In this work, an approach for adaptive content generation was developed, considering different player profiles. To this end, artificial neural network were implemented and compared, and integrated into Overlord, a procedural content generation orchestrator that, until then, did not employ such techniques. The results obtained enabled the selection of the best-performing model.*

Resumo. *Um dos desafios da indústria de jogos digitais é compreender as preferências do público a fim de oferecer experiências que mantenham elevados níveis de imersão e satisfação. Neste trabalho, foi desenvolvida uma abordagem para geração adaptativa de conteúdo, considerando diferentes perfis de jogadores. Para isso, foram implementados e comparados modelos de redes neurais artificiais, integrados ao Overlord, um orquestrador de geração procedural de conteúdo que, até então, não utilizava tais técnicas. Os resultados obtidos permitiram a seleção do modelo com melhor desempenho.*

1. Introdução

A indústria de jogos digitais, que projeta expandir de US$ 25,5 bilhões para US$ 37,74 bilhões até 2035 [Global Growth Insights 2024], apresenta o desafio de atender a públicos diversificados. Para isso, a adaptação de conteúdo é uma estratégia fundamental para aumentar a imersão e a satisfação do jogador, modificando elementos da experiência conforme seu perfil, comportamento e desempenho [Martins 2021, Balda 2020, de Lima et al. 2022].

Assim, diversas técnicas são utilizadas, desde heurísticas e lógica *fuzzy* até algoritmos de Aprendizado de Máquina (AM) e Aprendizado Profundo (AP), sendo estas últimas frequentemente mais eficazes para modelar a complexa interação do jogador [Rosa et al. 2023, Chrysafiadi et al. 2023, Chanel and Lopes 2020, de Lima et al. 2022]. No entanto, a eficácia dessas abordagens em cenários de alta complexidade e variabilidade, como os proporcionados por sistemas de Geração Procedural de Conteúdo (PCG), que atuam como orquestradores, ainda permanece pouco explorada, apesar de seu elevado interesse comercial e científico [Shaker et al. 2016, de Lima et al. 2022, Liapis et al. 2019].

Este projeto propõe investigar e comparar abordagens para a adaptação dinâmica de conteúdo integradas a um orquestrador de PCG, o *Overlord* [Pereira et al. 2024]. O sistema é responsável por coordenar dinamicamente múltiplas facetas de conteúdo gerado proceduralmente — Níveis (masmorras com quebra-cabeças de portas trancadas e posicionamento de inimigos), Narrativa (missões) e Regras (inimigos com diferentes atributos e mecânicas) — garantindo coerência estrutural entre os geradores e adequação ao perfil do jogador.

O sistema realiza a classificação do jogador com base em métricas da partida e, a partir dessa predição, orquestra de forma integrada os geradores de níveis, narrativa e regras. O objetivo central é adaptar múltiplos elementos do jogo de maneira consistente e personalizada, considerando distintos perfis e estilos de jogabilidade.

Para a condução dos experimentos, foi utilizada uma base de dados composta por aproximadamente 120 instâncias de gameplay (registros de sessões de jogo), posteriormente expandida para mais de 1000 instâncias por meio de técnicas estatísticas de aumento de dados (data augmentation), conforme metodologia validada na literatura [Pereira et al. 2025]. Esse procedimento visa mitigar os efeitos do tamanho reduzido da amostra original, permitindo uma avaliação mais robusta dos modelos de AM.

Para isso, arquiteturas de redes neurais artificiais representativas de modelos feedforward (FNN), recorrentes (RNN, LSTM, GRU), convolucionais (CNN) e temporais (TCN) foram adaptadas e avaliadas [Romero-Mendez et al. 2023, Rymarczyk et al. 2021, Heinz et al. 2017, Azevedo et al. 2020, You et al. 2019]. Também foram investigadas arquiteturas híbridas, como CNN-LSTM, CNN-GRU, RNN-LSTM e RNN-GRU [Chanel and Lopes 2020, An et al. 2019, Zhou et al. 2025, Kodiyan et al. 2017].

A avaliação experimental foi conduzida por meio de validação cruzada (k-fold cross-validation) e divisão treino-teste, empregando métricas de desempenho como acurácia, precisão, recall, F1-score, taxa de erro e coeficiente Kappa, além da análise de custo computacional (tempo de treinamento e inferência). Essa abordagem permite examinar tanto a capacidade preditiva quanto a eficiência dos modelos. Também foi utilizada a matriz de confusão para análise detalhada dos padrões de classificação.

Em etapa posterior, o modelo com melhor desempenho foi integrado ao sistema de adaptação do orquestrador, possibilitando sua avaliação em um cenário aplicado. Essa fase permitiu comparar a abordagem baseada em modelos treinados com a estratégia originalmente empregada pelo sistema, analisando impactos na qualidade da classificação de perfis e na adequação da adaptação do conteúdo ao jogador.

As principais contribuições deste trabalho são: (i) fornecer, por meio dos resultados obtidos, uma análise fundamentada dos pontos fortes e das limitações de cada abordagem em um cenário de orquestração procedural, contribuindo para a área de jogos sérios e entretenimento [Schrader 2022]; (ii) gerar subsídios teóricos e práticos para o desenvolvimento de sistemas adaptativos mais robustos; e (iii) oferecer uma contribuição relevante para a área de AM, ao avaliar a capacidade de generalização e a eficiência de diferentes arquiteturas em ambientes interativos e estocásticos.

O artigo está organizado da seguinte forma: a Seção 2 descreve a metodologia; a Seção 3 discute os experimentos e resultados; e a Seção 4 apresenta as conclusões.

Referências

An, M., Wu, F., Wu, C., Zhang, K., Liu, Z., and Xie, X. (2019). Neural news recommendation with long- and short-term user representations.

Azevedo, V., Nedjah, N., and Mourelle, L. (2020). Identificação do perfil de clientes utilizando redes neurais convolucionais. pages 1–8.

Balda, H. D. F. (2020). Improvement of player experience through dynamic difficulty adjustment using behavioral patterns and machine learning. Diss. (graduação), Tokyo University of Technology.

Chanel, G. and Lopes, P. (2020). User evaluation of affective dynamic difficulty adjustment based on physiological deep learning. In *Augmented Cognition. Theoretical and Technological Approaches*, pages 3–23, Cham. Springer International Publishing.

Chrysafiadi, K., Kamitsios, M., and Virvou, M. (2023). Fuzzy-based dynamic difficulty adjustment of an educational 3d-game. *Multimedia Tools and Applications*, 82(18):27525–27549.

de Lima, E. S., Silva, B. M., and Galam, G. T. (2022). Adaptive virtual reality horror games based on machine learning and player modeling. *Entertainment Computing*, 43:100515.

Global Growth Insights (2024). Video game market size, share, growth, and industry analysis, by types (kids, adults), applications (action, adventure and role playing, arcade, strategy, simulation, driving, other), and regional insights and forecast to 2035. `https://www.globalgrowthinsights.com/pt/market-reports/video-game-market-107798`. Acesso em: 16 mar. 2026.

Heinz, S., Bracher, C., and Vollgraf, R. (2017). An lstm-based dynamic customer model for fashion recommendation.

Kodiyan, D., Hardegger, F., Neuhaus, S., and Cieliebak, M. (2017). Author profiling with bidirectional rnns using attention with grus. In Cappellato, L., Ferro, N., Goeuriot, L., and Mandl, T., editors, *Working Notes of CLEF 2017 - Conference and Labs of the Evaluation Forum, Dublin, Ireland, September 11-14, 2017*, CEUR Workshop Proceedings. CEUR-WS.org.

Liapis, A., Yannakakis, G. N., Nelson, M. J., Preuss, M., and Bidarra, R. (2019). Orchestrating game generation. *IEEE Transactions on Games*, 11(1):48–68.

Martins, B. d. H. (2021). Assessing game player profiles through agent-based simulation.

Pereira, L. T., Teoi, T. Y., and Toledo, C. F. M. (2025). Evaluating a procedural content orchestrator gameplay data and classifying user profiles. *Journal on Interactive Systems*, 16(1):490–504.

Pereira, L. T., Viana, B. M. F., and Toledo, C. F. M. (2024). A system for orchestrating multiple procedurally generated content for different player profiles. *IEEE Transactions on Games*, 16(1):64–74.

Romero-Mendez, E., Santana-Mancilla, P., Garcia-Ruiz, M., Montesinos-López, O., and Anido-Rifón, L. (2023). The use of deep learning to improve player engagement in a video game through a dynamic difficulty adjustment based on skills classification. *Applied Sciences*, 13:8249.

Rosa, M. P., Castanho, C., Silva, T., Sarmet, M., and Jacobi, R. (2023). *Dynamic Difficulty Adjustment by Performance and Player Profile in Platform Game*, pages 3–16.

Rymarczyk, P., Golabek, P., Sylwia, and Rzemieniak, M. (2021). Profiling and segmenting clients with the use of machine learning algorithms. *EUROPEAN RESEARCH STUDIES JOURNAL*, XXIV:513–522.

Schrader, C. (2022). *Serious Games and Game-Based Learning*, pages 1–14. Springer Singapore, Singapore.

Shaker, N., Togelius, J., and Nelson, M. J. (2016). Procedural content generation in games.

You, J., Wang, Y., Pal, A., Eksombatchai, P., Rosenburg, C., and Leskovec, J. (2019). Hierarchical temporal convolutional networks for dynamic recommender systems. In *The World Wide Web Conference*, WWW '19, page 2236–2246, New York, NY, USA. Association for Computing Machinery.

Zhou, X., Li, F., Hu, J., and Liang, J. (2025). A customer profiling method for personalized service in retail pharmacies. In *Proceedings of the 2025 6th International Conference on Computer Information and Big Data Applications*, CIBDA '25, page 1082–1086, New York, NY, USA. Association for Computing Machinery.