Análise Comparativa de Arquiteturas de Redes Neurais

Para Classificação de Perfis de Jogadores

Pedro G. Gonçalves

Pós-Graduacao – Redes Neurais Artificiais
Universidade Estadual Paulista (UNESP)

Junho de 2026

Introdução

Objetivos

- Conduzir um estudo para apoiar a personalização de conteúdo, por meio da identificação de padrões em perfis de jogadores
- Comparar diferentes modelos de redes neurais

Trabalhos relacionados

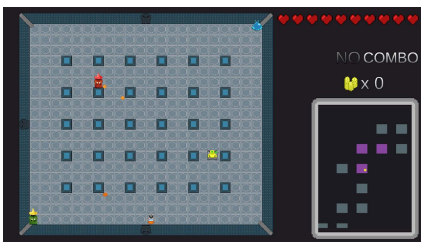


Figura: Pereira et al. (2022)

Overlord

- 119 → 1000+ instâncias
- Dados de gameplay + perfil
  - Níveis
  - Regras
  - Narrativa

Data Augmentation

- Pereira et al. (2025)
- Ruído, Escala

Redes Neurais

Modelos

- Feedforward
  - Feedforward Neural Network (FNN)
- Recorrente
  - Recurrent Neural Network (RNN)
  - Long Short-Term Memory (LSTM)
  - Gated Recurrent Unit (GRU)
- Convolucional
  - Convolutional Neural Network (CNN)
  - Temporal Convolutional Network (TCN)

Modelos híbridos

- FNN-LSTM
- FNN-GRU
- RNN-LSTM
- RNN-GRU
- CNN-LSTM
- CNN-GRU
- TCN-LSTM
- TCN-GRU

Estratégia

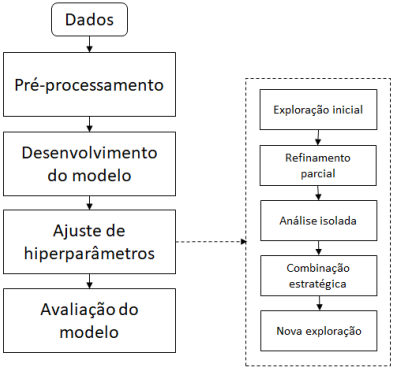


Figura: Fluxo do desenvolvimento dos modelos de redes neurais

Resultados

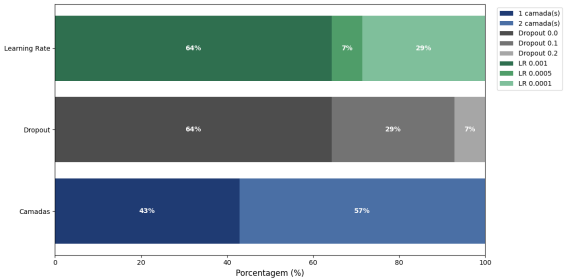


Figura: Distribuição percentual do desempenho das combinações de hiperparâmetros, considerando taxa de aprendizagem, número de camadas e uso de dropout, para os dois melhores resultados de cada fase.

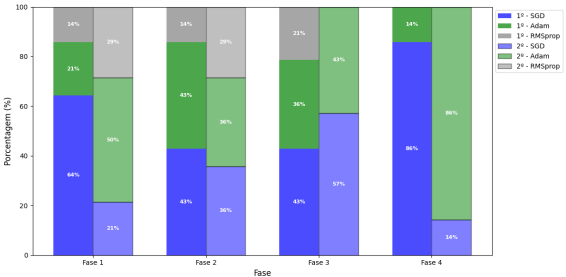


Figura: Distribuição percentual do desempenho dos otimizadores ao longo das etapas de validação de hiperparâmetros, para os dois melhores resultados de cada fase

Resultados

Modelo	Acc (Test)	F1	Prec (Test)	Recall (Test)	Kappa (Test)	Gap	CV Mean	CV Std
LSTM	0.2854	0.2097	0.3646	0.2854	0.0946	-0.0316	0.2246	0.0189
GRU	0.2948	0.2356	0.2466	0.2948	0.1200	0.2624	0.4538	0.0169
FNN	0.2668	0.1928	0.2035	0.2668	0.0812	0.1936	0.4073	0.0749
FNN+LSTM	0.2593	0.1825	0.1849	0.2593	0.0355	-0.0504	0.2190	0.0114
FNN+GRU	0.2369	0.1416	0.2090	0.2369	0.397	0.1169	0.3557	0.0210
CNN	0.2780	0.1778	0.3983	0.2780	0.0819	0.5243	0.7569	0.0971
CNN+LSTM	0.2817	0.2025	0.2958	0.2817	0.0544	0.3052	0.6263	0.0407
CNN+GRU	0.2817	0.1762	0.3142	0.2817	0.0817	0.1482	0.4286	0.0342
RNN	0.2743	0.2294	0.4968	0.2743	0.1278	0.4321	0.6213	0.0539
RNN+LSTM	0.2836	0.1772	0.1972	0.2836	0.1039	0.1872	0.4835	0.0316
RNN+GRU	0.2463	0.1798	0.1628	0.2463	0.0817	0.2168	0.4555	0.0427
TCN	0.2425	0.1033	0.0881	0.2425	0.0076	-0.0120	0.2129	0.0151
TCN+LSTM	0.2687	0.1923	0.2441	0.2687	0.0711	0.1421	0.3905	0.0283
TCN+GRU	0.2407	0.1783	0.174	0.2407	0.0349	0.0564	0.2818	0.0186

Figura: Melhores resultados dos modelos (métricas de teste)

Conclusão

Percepções

- Identificação de melhores configurações de hiperparâmetros
- O banco de dados atual é insuficiente

Trabalhos futuros

- Técnicas de balanceamento
- Modelos clássicos de aprendizado de máquina
- Coleta adicional de dados
- Testar o modelo diretamente na aplicação
- Ampliar testes com hiperparâmetros

Referencias I

Artigos cientificos

1. Pereira, L., Viana, B., and Toledo, C. *A system for orchestrating multiple procedurally generated content for different player profiles* 2022. In IEEE Transactions on Games, PP:1–11.
2. Pereira, L. T., Teoi, T. Y., and Toledo, C. F. M. *Evaluating a procedural content orchestrator gameplay data and classifying user profiles* 2025. In Journal on Interactive Systems, 16(1):490–504.
3. Kline, R. B. *Principles and Practice of Structural Equation Modeling* 2016. 4 edition. The Guilford Press, New York.

Obrigado!