Filtragem Colaborativa para Perfilamento e Recomendação de Conteúdo em Jogos Digitais

Pedro G. Gonçalves

Instituto de Geociências e Ciências Exatas – Universidade Estadual Paulista (UNESP)
Rio Claro – SP – Brazil

pedro.g.goncalves@unesp.br

Abstract. *Understanding player preferences is one of the main challenges in the digital games industry, as it is essential for promoting immersive and satisfying experiences. This work proposes a content recommendation approach based on gameplay data from different users, using collaborative filtering techniques. Different models were implemented and compared, and the best-performing one was selected, achieving an RMSE of 0.66 and an MAE of 0.55, as well as a precision of 0.12, recall of 1, hit rate of 0.82, and MRR of 0.2862. The generated recommendations were analyzed from different perspectives, including user–item relationships, as well as profile-based segmented approaches. The results demonstrate the model's ability to recommend existing levels and suggest new content consistently. As a contribution, this work highlights the potential of collaborative filtering to support player profiling and content personalization in digital games, emphasizing scenarios in which different approaches can be effectively applied.*

Resumo. *A compreensão das preferências dos jogadores é um dos principais desafios da indústria de jogos digitais, sendo fundamental para promover experiências imersivas e satisfatórias. Este trabalho propõe uma abordagem de recomendação de conteúdo baseada em dados de partidas de diferentes usuários, utilizando técnicas de filtragem colaborativa. Foram implementados e comparados diferentes modelos, sendo selecionado aquele que apresentou RMSE de 0,66 e MAE de 0,55, além de precision de 0,12, recall de 1, hit rate de 0,82 e MRR de 0,2862. As recomendações geradas foram analisadas sob diferentes perspectivas, incluindo relações entre usuários e itens, bem como abordagens segmentadas por perfis. Os resultados demonstram a capacidade do modelo em recomendar níveis existentes e sugerir novos conteúdos de forma consistente. Como contribuição, o trabalho evidencia o potencial da filtragem colaborativa no apoio ao perfilamento de jogadores e na personalização de conteúdo em jogos digitais, destacando cenários em que diferentes abordagens podem ser aplicadas de forma eficaz.*

1. Introdução

A indústria de jogos digitais, que projeta expandir de US$ 25,5 bilhões para US$ 37,74 bilhões até 2035 [Global Growth Insights 2024], apresenta o desafio de atender a públicos diversificados. Para isso, compreender o comportamento e as preferências do jogador torna-se fundamental para produzir conteúdos que aumentem sua imersão e satisfação [Martins 2021, Balda 2020].

Assim, diversas técnicas são utilizadas, como heurísticas, lógica *fuzzy*, filtragem colaborativa e algoritmos de aprendizado de máquina e aprendizado profundo [Rosa et al. 2023, Hannon et al. 2010, Chrysafiadi et al. 2023, Chanel and Lopes 2020, de Lima et al. 2022, Sanker 2025], com o objetivo de promover a personalização, que pode ser realizada por meio de técnicas de recomendação baseadas em dados de comportamento, desempenho ou avaliação do jogador [Sanker 2025, Balda 2020].

Dentre essas técnicas, a filtragem colaborativa contribui para a identificação de jogadores semelhantes com base em seus padrões de interação, possibilitando a inferência de preferências e comportamentos de um jogador a partir dos dados de seus vizinhos mais próximos. [Sanker 2025, Grcar 2004].

Dessa forma, padrões observados em grupos de jogadores com perfis semelhantes podem ser utilizados para estimar características de novos jogadores, mesmo na ausência de dados completos. Esse processo viabiliza a associação desses jogadores a perfis representativos, permitindo a recomendação de conteúdo de forma adequada [Sanker 2025, Chen et al. 2021].

Com base nisso, este projeto investigou abordagens para recomendação de conteúdo utilizando a filtragem colaborativa como mecanismo de personalização. Para isso, foi utilizada uma base de dados composta por informações de jogadores e partidas, coletada no contexto do *Overlord*, um orquestrador de Geração Procedural de Conteúdo [Pereira et al. 2022] e disponibilizada no trabalho [Pereira et al. 2024].

Essa base é composta por aproximadamente 119 instâncias de jogabilidade (registros de sessões de jogo), posteriormente expandida para mais de 1000 instâncias por meio de técnicas estatísticas de aumento de dados (*data augmentation*), conforme metodologia validada na literatura [Pereira et al. 2025]. Esse procedimento visou mitigar os efeitos do tamanho reduzido da amostra original e permitir uma avaliação mais robusta dos modelos. Ela reúne dados relacionados aos níveis gerados (masmorras com quebra-cabeças e posicionamento de inimigos), narrativa (missões) e regras (atributos e mecânicas dos inimigos), permitindo a extração de padrões de comportamento e desempenho.

A partir desses dados, buscou-se identificar e agrupar jogadores em diferentes perfis de jogabilidade, possibilitando a recomendação de níveis mais adequados, bem como a indicação separada de parâmetros como dificuldade de inimigos e preferências por missões.

Com os dados estruturados, foram implementados e comparados três modelos: (i) a filtragem baseada em item, na qual é considerada a avaliação do nível pelo jogador; (ii) a filtragem baseada no usuário, a partir de dados de seu comportamento na partida; (iii) e um modelo misto de ambas [Hannon et al. 2010, Su and Khoshgoftaar 2009, Koren et al. 2022]. Para isso, foram utilizadas as medidas de similaridade de cosseno e correlação de Pearson para quantificar a semelhança entre usuários e itens [Sanker 2025].

A avaliação da filtragem colaborativa foi realizada por meio de métricas de predição *RMSE* e *MAE*, comparando as notas previstas com as notas reais no conjunto de teste. Para isso, adotou-se uma divisão dos dados, utilizando o conjunto de treino para aprender os padrões de similaridade entre jogadores e itens, enquanto o conjunto de teste foi utilizado para validação das predições. Adicionalmente, foram utilizadas métricas de *precision*, *recall*, *hit rate* e *MRR* para avaliar a qualidade das recomendações geradas

[Su and Khoshgoftaar 2009, Chen et al. 2021].

As principais contribuições deste trabalho são: (i) fornecer, por meio dos resultados obtidos, uma análise comparativa dos pontos fortes e das limitações das abordagens investigadas, contribuindo para a área de jogos sérios e entretenimento [Schrader 2022]; (ii) oferecer subsídios teóricos e práticos para o desenvolvimento de sistemas de recomendação e adaptação mais robustos em jogos digitais; e (iii) contribuir para a área de inteligência artificial ao investigar a aplicação de filtragem colaborativa na modelagem do comportamento de jogadores, avaliando sua capacidade de perfilamento e recomendação em ambientes interativos.

O artigo está organizado da seguinte forma: a Seção 2 apresenta os trabalhos relacionados sobre a adaptação de jogos; a Seção 3 descreve a metodologia; a Seção 4 discute os resultados; e a Seção 5 apresenta as conclusões.

2. Trabalhos Relacionados

2.1. Adaptação de conteúdo

A adaptação de conteúdo refere-se ao processo de modificar elementos de um sistema com o objetivo de aprimorar a experiência do usuário. Em estudos recentes, essa adaptação tem sido implementada de forma dinâmica, destacando-se abordagens como Geração Procedural de Conteúdo e Ajuste Dinâmico de Dificuldade [Vang 2022, Pereira et al. 2025].

Essas estratégias permitem que o sistema ajuste, por exemplo, o nível de dificuldade para evitar a frustração ou a perda de interesse do jogador, bem como modifique o conteúdo apresentado a fim de introduzir novidades e, consequentemente, aumentar o engajamento e a atenção durante a interação com o jogo.

Além disso, sistemas de recomendação permitem compreender comportamentos e preferências dos usuário, sendo aplicados em diferentes contextos, desde o comércio físico até as redes sociais [Zhou et al. 2025, Hannon et al. 2010], e possibilitam recomendar ao jogador conteúdos de seu interesse [Charity et al. 2023].

2.2. Facetas Criativas dos Jogos

Jogos digitais possuem diversas facetas que contribuem para sua concepção; portanto, alguns autores consideram necessário defini-las de forma estruturada, a fim de organizar o processo de criação. Dessa forma, foram definidas seis facetas criativas: áudio, níveis, narrativa, regras, visuais e jogabilidade [Liapis et al. 2014, Liapis et al. 2019].

Áudio refere-se a qualquer elemento sonoro. Níveis correspondem a elementos que o jogador deve superar, como ambientes, objetos ou progressão. Narrativa compreende a história do personagem, do mundo e as missões. Regras são os parâmetros, o estado ou condições. Visuais englobam texturas, aparências e efeitos visuais. Por fim, jogabilidade refere-se aos aspectos de simulação ou testes.

Essa definição fornece uma nomenclatura que permite uma melhor organização e análise dos elementos, podendo servir como base para o design de jogos ao contribuir para a identificação de perfis de jogadores e características de grupo [Carneiro et al. 2021, Martins 2021], mesmo que jogos como *Dispatch*[1] apresentem essa ambiguidade, na qual

[1]Dispatch. Disponível em: https://store.steampowered.com/app/2592160/Dispatch/. Acesso em: 5 maio 2026.

a jogabilidade interfere na narrativa e nos níveis.

2.3. Overlord

O *Overlord* é um orquestrador de conteúdo responsável por coordenar três facetas criativas do jogo: (i) *níveis*, que produz masmorras compostas por salas contendo inimigos, *NPCs* e itens; (ii) *regras*, responsável por selecionar os parâmetros dos inimigos, tais como saúde, velocidade de movimento e dano causado; e (iii) *narrativa*, que define o *template* da missão de acordo com o perfil do jogador [Pereira et al. 2022].

O orquestrador considera o perfil do jogador para pós-processar o conteúdo gerado pelos diferentes sistemas, sendo assim adaptativo. Sua capacidade foi testada, obtendo resultados positivos para a diversão e a adaptação ao perfil [Pereira et al. 2022, Teoi et al. 2024]. Para este trabalho, foram utilizados dados coletados em um jogo orquestrado pelo *Overlord*, no qual foram testadas e descritas as experiências dos jogadores nos estudos supracitados.

2.4. Perfilamento

O perfilamento consiste na inferência de traços de personalidade a partir do comportamento observado, sendo aplicável em diversos contextos [Rymarczyk et al. 2021, Pereira et al. 2022, Koren et al. 2022], incluindo jogos eletrônicos, nos quais é possível identificar características do usuário [Carvalho and Macedo 2013, Santos et al. 2019].

Compreender as motivações dos jogadores é fundamental para o desenvolvimento e a pesquisa em jogos, especialmente no contexto de jogos sérios, nos quais o engajamento é um requisito essencial para a efetividade dos resultados de aprendizagem [Hookham and Nesbitt 2019, Orhan Göksün and Gürsoy 2019].

Para a adaptação de conteúdo neste contexto, por meio do perfilamento, adotou-se a definição conhecida como os quatro fatores de motivação [Yee and Ducheneaut 2018]: ***A**chievement*: refere-se a jogadores que priorizam conquistas e fortalecimento de seus personagens, ***C**reativity* caracteriza jogadores que valorizam personalização e exploração, ***I**mmersion* caracteriza jogadores interessados na narrativa e em incorporar seu personagem e ***M**astery* representa jogadores motivados por desafios, resolução de problemas e experiências estratégicas.

Cada fator recebe um valor único entre 1 e 4, que representa sua influência, sendo 1 o mínimo e 4 o máximo. Por exemplo, um jogador do tipo *Mastery* receberia valor 4 para esse fator, enquanto os demais variariam entre 1 e 3. Essa é a representação utilizada pelo *Overlord* e, neste trabalho, ela foi mantida para facilitar o entendimento e a comparação dos resultados [Pereira et al. 2022].

2.5. Filtragem Colaborativa

A Filtragem Colaborativa é uma das técnicas de recomendação mais consolidadas para predizer com precisão os interesses dos usuários. Atualmente, ela é principalmente categorizada em filtragem baseada em itens e filtragem baseada em usuários [Chen et al. 2021].

A filtragem baseada em usuários identifica comportamentos semelhantes entre os usuários e recomenda itens que usuários com perfis parecidos apreciaram. Por sua vez,

a filtragem baseada em itens recomenda produtos com base nas interações anteriores do próprio usuário, sugerindo itens similares aos que ele gostou. Esses modelos são complementares e, por isso, sistemas modernos os integram em abordagens híbridas para melhorar a precisão das recomendações [Sanker 2025]. Para viabilizar a recomendação, a similaridade entre usuários ou itens pode ser calculada por diferentes métricas, tais como a similaridade do cosseno e a correlação de Pearson [Chen et al. 2021].

Uma das principais características dessa técnica é a capacidade de identificar relações entre itens que não possuem similaridade de conteúdo, mas que estão conectados por meio dos grupos de usuários que os utilizam. Assim, esses grupos representam perfis específicos de usuários [Grcar 2004].

Essa técnica é utilizada no contexto de jogos conforme demonstrado no trabalho de [Charity et al. 2023], que desenvolveu um sistema de recomendação de jogos similares, em que os resultados do estudo com usuários mostraram que as características geradas pelo modelo apresentaram desempenho equivalente às humanas em jogos reais. Além disso, a literatura mostrou bons resultados ao unir os conceitos de perfilamento e filtragem colaborativa [Grcar 2004, Zhou et al. 2025, Marlin 2003]. Dessa forma, a filtragem colaborativa pode ser aplicada neste trabalho para identificar perfis de usuários e, consequentemente, recomendar conteúdos mais adequados às preferências de cada usuário, contribuindo para a personalização do sistema de recomendação.

3. Metodologia

3.1. Tecnologia

O sistema de recomendação baseado em filtragem colaborativa foi desenvolvido utilizando a linguagem de programação *Python*, no ambiente de desenvolvimento *Google Colab*[2].

3.2. Coleta de dados

As métricas de comportamento do jogador durante a partida foram coletadas por meio de registros, gerados automaticamente ao longo da execução do jogo, os quais são armazenados quando o jogador conclui a fase ou quando encerra a partida. Esses dados foram coletados utilizando variáveis inteiras e booleanas, permitindo a representação de comportamentos e estados de resultado da partida.

Foram registrados dados relacionados ao desempenho do jogador, à sua interação com os elementos da masmorra e ao estado final da partida, incluindo métricas de combate, exploração, progressão e conclusão da sessão.

A coleta dos dados relacionados ao perfil foi realizada por meio da aplicação de um questionário na primeira vez em que o jogador acessa o jogo. O instrumento foi baseado e adaptado ao conceito dos quatro fatores de motivação propostos na literatura [Yee and Ducheneaut 2018], com o objetivo de inferir o perfil motivacional do jogador.

O questionário é composto por doze itens, sendo distribuídos da seguinte forma: duas questões relacionadas à experiência geral com jogos, três questões associadas ao perfil de *Mastery*, duas questões para cada um dos demais perfis e uma questão adicional, utilizada como fator de penalização para perfis não relacionados ao *Mastery*. Com

[2]Google Colab. Disponível em: https://colab.research.google.com/. Acesso em: 6 maio 2026.

base nas respostas, são calculados escores para cada um dos quatro fatores de motivação. Essas equações combinam as respostas dos jogadores para estimar a intensidade de cada motivação [Pereira et al. 2022].

3.3. Procedimento

om base nas informações presentes no banco de dados, iniciou-se a etapa de implementação. O processo experimental foi estruturado em seis etapas: (i) divisão dos dados, (ii) aumento de dados, (iii) tipo de filtragem, (iv) cálculo de similaridade, (v) validação do modelo e (vi) recomendações

3.3.1. Divisão dos dados

O conjunto de dados foi particionado em subconjuntos de treino e teste utilizando a estratégia *Leave-One-Out*, na qual, para cada usuário, uma única interação é reservada para o conjunto de teste, enquanto as demais são utilizadas no treinamento. Essa abordagem é amplamente adotada em sistemas de recomendação, sendo considerada uma prática consolidada na literatura [de Oliveira 2019, Ricci et al. 2010, Pinto 2021].

3.3.2. Aumento de dados

Em seguida, aplicou-se aumento de dados exclusivamente ao conjunto de treino, prática recomendada na literatura para evitar vazamento de informação e preservar a validade da avaliação experimental [Ricci et al. 2010].

Dessa forma, foi adotado o melhor cenário aplicado a este conjunto de dados, no qual os melhores resultados foram obtidos com uma ampliação de dez vezes em relação ao baseline. Esse cenário inclui as 119 métricas originais, que foram aumentadas seis vezes com ruído (gerando 714 novas instâncias), além de 119 novas instâncias obtidas a partir de quatro diferentes configurações de escalonamento, que consistem na multiplicação das instâncias originais por 0,9; 0,95; 1,05 e 1,1 (totalizando 476 novas instâncias) [Pereira et al. 2025].

Após o processo de aumento, o conjunto de treinamento passou a conter 1309 instâncias de dados e apresentou uma acurácia média de quase 95%, com um desvio padrão de 0,031 entre os folds [Pereira et al. 2025].

3.3.3. Configuração de entrada

Foram definidas três abordagens de filtragem colaborativa: (i) baseada em usuário, (ii) baseada em itens e (iii) um modelo híbrido, combinando as duas estratégias anteriores.

Todas as abordagens utilizam três entradas principais para a construção da matriz usuário-item: a coluna *user*, responsável por identificar cada usuário do sistema e permitir o agrupamento de suas interações, viabilizando a construção de um perfil individual de preferências; a coluna *item*, que representa os itens (conteúdos) que tiveram interações de comportamento ou avaliação dos usuários, relacionando cada interação ao objeto específico do sistema de recomendação; e o campo *weight*, utilizado para modelar

a preferência do usuário a partir de avaliações ou comportamento, servindo como base para o cálculo de similaridade e para a geração de recomendações.

A coluna *user* foi definida, em todos os casos, a partir do identificador único do jogador presente no conjunto de dados. As demais colunas, no entanto, foram construídas a partir de diferentes estratégias de representação, conforme a abordagem adotada.

Para a definição do campo *weight*, foram avaliadas três estratégias distintas. Na abordagem baseada em itens, utilizou-se a coluna referente ao formulário pós-jogo, que representa a avaliação explícita do usuário após a experiência na masmorra. Já na abordagem baseada em comportamento, o valor de *weight* foi calculado a partir da média de métricas que representam o desempenho do jogador em quatro facetas da criatividade: taxa de sucesso (A), sobrevivência (I), combate (M) e progressão no mapa (C). Essa estratégia busca capturar preferências implícitas a partir do comportamento observado. Na abordagem híbrida, o valor final de *weight* foi obtido por meio da média entre os valores gerados pelas abordagens baseada em itens e baseada em comportamento.

Além disso, para todas as abordagens, foram consideradas três configurações distintas para a coluna *item*: (i) uma representação baseada no perfil estrutural da masmorra (por exemplo, A = 4, C = 2, M = 1, I = 3); (ii) uma representação agregada da masmorra a partir da identificação do nível, considerando a proporção estimada de seus elementos característicos (por exemplo, ***M**astery*: 20, ***T**alk (Immersion)*: 30, ***G**oal (Achievement)*: 10, ***E**xploration (Creativity)*: 40); e (iii) uma representação granular, composta por atributos quantitativos que descrevem diretamente os elementos estruturais da masmorra, como número de salas, chaves, portas e cadeados.

Inicialmente, foram realizados 12 experimentos, organizados em três grupos de acordo com o tipo de entrada: perfis (1–4), representação da masmorra (5–8) e características granulares (9–12). Em cada grupo, variaram-se a métrica de similaridade — cosseno ou correlação de Pearson — e a abordagem de filtragem — baseada em itens ou baseada em usuários, conforme detalhado na Tabela 1.

Tabela 1. Distribuição dos experimentos por tipo de entrada, similaridade e filtragem.

Grupo	Exp.	Similaridade	Filtragem
Perfis	1	Cosseno	Item
	2	Pearson	Item
	3	Cosseno	Usuário
	4	Pearson	Usuário
Masmorra	5	Cosseno	Item
	6	Pearson	Item
	7	Cosseno	Usuário
	8	Pearson	Usuário
Granular	9	Cosseno	Item
	10	Pearson	Item
	11	Cosseno	Usuário
	12	Pearson	Usuário

3.3.4. Cálculo de similaridade

Todas as abordagens de filtragem colaborativa foram submetidas, separadamente, ao cálculo de similaridade por cosseno e à correlação de Pearson.

A similaridade por cosseno calcula o cosseno do ângulo entre dois vetores [Chen et al. 2021], sendo definida como:

$$similaridade(A, B) = \cos(\theta) = \frac{\sum_{i=1}^{n} A_i B_i}{\sqrt{\sum_{i=1}^{n} A_i^2}\sqrt{\sum_{i=1}^{n} B_i^2}}$$

em que A e B representam os vetores de usuários ou itens, e A_i e B_i correspondem aos valores associados a cada dimensão do vetor.

Já a correlação de Pearson mede o grau de correlação linear entre as classificações de usuários ou itens [Grcar 2004], sendo definida pela seguinte fórmula:

$$similaridade(A, B) = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2}\sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2}}$$

em que x_i e y_i representam os valores observados, enquanto $\bar{x}$ e $\bar{y}$ correspondem às médias dos vetores analisados.

3.3.5. Validação do modelo

Por fim, a qualidade das abordagens foi avaliada por meio das métricas *RMSE* e *MAE*, além das métricas de *precision*, *recall*, *MRR* e *hit rate* amplamente utilizadas na avaliação de sistemas de recomendação [Su and Khoshgoftaar 2009, Chen et al. 2021].

As métricas *RMSE* e *MAE* foram empregadas para mensurar a qualidade das predições realizadas pelos modelos, avaliando o erro entre os valores previstos e os valores reais observados. Já as métricas de precisão e *recall* foram utilizadas para analisar a qualidade das recomendações, considerando tanto a relevância dos itens recomendados quanto a capacidade do sistema de recuperar itens relevantes para os usuários [Chen et al. 2021].

Para a análise dos resultados, considera-se que, quanto menor o valor do *RMSE* e do *MAE*, melhor será o desempenho. Já para *precision*, *recall*, *hit rate* e *MRR*, quanto maior o valor, melhor será o desempenho [Pinto 2021, Ricci et al. 2010]. Conforme Kline [Kline 2016], o contexto da análise pode afetar os resultados. No entanto, esses fatores podem ser contornados por meio de uma análise local, que reanalisa os dados sob diferentes pressupostos.

A seguir, são apresentadas as definições das métricas [Chen et al. 2021] utilizadas na avaliação dos modelos, bem como os valores encontrados na literatura para contextos semelhantes, a fim de permitir uma comparação adequada.

- **RMSE (*Root Mean Squared Error*)**
  Mede a raiz do erro quadrático médio entre os valores reais e os valores preditos pelo sistema de recomendação. Quanto menor o valor do RMSE, melhor a capacidade preditiva do modelo.

$$RMSE = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(r_i - \hat{r}_i)^2} \tag{1}$$

onde r_i representa o valor real, $\hat{r}_i$ o valor predito e N o número total de predições.

- **MAE (*Mean Absolute Error*)**
  Mede o erro absoluto médio entre os valores reais e os valores previstos pelo modelo, sendo menos sensível a grandes erros quando comparado ao RMSE.

$$MAE = \frac{1}{N}\sum_{i=1}^{N}|r_i - \hat{r}_i| \tag{2}$$

onde r_i corresponde ao valor real, $\hat{r}_i$ ao valor predito e N ao total de predições.

- **Precision**
  Avalia a proporção de itens recomendados que são realmente relevantes.

$$Precision = \frac{|TP|}{|TP + FP|} \tag{3}$$

Valores maiores indicam melhor qualidade das recomendações.

- ***Recall***
  Mede a capacidade do sistema em recuperar itens relevantes dentre todos os itens relevantes disponíveis.

$$Recall = \frac{|TP|}{|TP + FN|} \tag{4}$$

Valores elevados de *recall* indicam maior cobertura de itens relevantes pelo sistema de recomendação.

- ***MRR* (*Mean Reciprocal Rank*)**
  Mede a posição do primeiro item relevante na lista de recomendações, considerando o inverso do seu ranking.

$$MRR = \frac{1}{|Q|}\sum_{i=1}^{|Q|}\frac{1}{rank_i} \tag{5}$$

em que $rank_i$ corresponde à posição do primeiro item relevante para o usuário i.
Valores elevados de *MRR* indicam que itens relevantes aparecem nas primeiras posições das listas de recomendação.

- ***Hit Rate***
  Mede a proporção de casos em que um item relevante aparece na lista de recomendações.

$$Hit\ Rate = \frac{N_{hits}}{N_{rec}} \tag{6}$$

em que N_{hits} representa o número de recomendações que contêm ao menos um item relevante, e N_{rec} corresponde ao total de recomendações realizadas.
Valores elevados de *hit rate* indicam que o sistema consegue incluir ao menos um item relevante entre os recomendados.

Tabela 2. Valores de referência na literatura para as métricas de avaliação.

Métrica	Trabalhos	Valores
RMSE	[Koren et al. 2022]; [Chen et al. 2021]	0,8556; 0,924965
MAE	[Marlin 2003]; [Chen et al. 2021]	0,75; 0,728071
Precision	[Sánchez and Bellogín 2019]	0.199
Recall	[Rymarczyk et al. 2021]; [Sánchez and Bellogín 2019]; [de Oliveira 2019]	0,190; 0,177; 0,434
MRR	[de Oliveira 2019]	0,2865; 0,2253; 0,1348
Hit Rate	[He et al. 2017]	0,73; 0,88

A Tabela 2 apresenta os valores de referência encontrados na literatura para as métricas de avaliação utilizadas neste estudo.

Além disso, segundo [Ricci et al. 2010], a escolha do critério de avaliação deve estar alinhada ao objetivo do sistema: se o foco é predizer a nota exata, deve-se priorizar *RMSE* e *MAE*; se o objetivo é realizar recomendações assertivas, o foco deve ser *precision*, *recall* e *hit rate*. Vale ressaltar que *RMSE* e *MAE* podem prever com precisão as notas, porém, conforme apontado na literatura [McNee and Riedl 2006], nem sempre uma predição exata reflete a melhor experiência para o usuário, que muitas vezes busca descobrir itens novos em vez de rever algo já conhecido.

3.3.6. Recomendações

Após o cálculo das similaridades, o modelo tornou-se apto para realizar recomendações. Dessa forma, diferentes estratégias de recomendação foram implementadas, entre elas:

- Recomendação de itens semelhantes a um item de referência, com base na similaridade entre itens;
- Recomendação de itens para um usuário a partir da similaridade com outro usuário;
- Recomendação de itens utilizando múltiplos usuários similares, considerando a contribuição conjunta de usuários com perfis semelhantes;
- Recomendação híbrida, realizada a partir da combinação das predições obtidas pelos modelos baseados em itens e em usuários, utilizando a média ponderada entre ambos os métodos para definir os itens de maior relevância prevista.

Além disso, com base na validação, a melhor abordagem do campo *item* foi usada para construir tabelas de atributos como de missões, dificuldade, interação com *NPCs*, masmorras. Isso permitiu avaliar a influência das quatro facetas e gerar recomendações mais segmentadas.

Com isso, a recomendação foi realizada da seguinte forma: inicialmente, com base no campo *item*; em seguida, pelas tabelas específicas, considerando a média dos melhores itens; depois, pelos níveis existentes com base nas métricas; e, por fim, pela sugestão de uma masmorra com novas configurações.

Ressalta-se que, para fins de visualização, a quantidade de usuários e masmorras foi limitada nas tabelas e figuras que apresentam esses elementos, embora o *dataset* contenha um número maior disponível para o cálculo de similaridade.

4. Resultados

4.1. Análise das métricas

Na Tabela 3, nossas métricas apresentaram um comportamento de flutuação entre diferentes experimentos, com alguns se destacando em determinados indicadores e outros em métricas distintas. Seguimos a orientação de [Ricci et al. 2010], que resume que as métricas de erro de predição *(RMSE, MAE)* são melhores quanto menores, enquanto as métricas de qualidade da lista *(precision, recall, hit rate)* são melhores quanto maiores para analisar os resultados obtidos nesse trabalho.

Inicialmente, observamos que os melhores resultados foram obtidos pelos experimentos baseados em item (vide Tabela 1) em cada grupo e como não existe um único critério para definir o melhor experimento, optamos por selecionar os modelos com melhor equilíbrio entre as métricas de erro e as de ranqueamento. Dessa forma, os experimentos que apresentam o melhor compromisso são os Experimentos 1, 2, 5 e 6, pois apresentam bons valores tanto para as métricas de erro quanto para as de ranqueamento. Os demais experimentos foram descartados: os Experimentos 3, 4, 7 e 8 apresentam erros elevados (*RMSE* e *MAE* altos), enquanto os Experimentos 9 a 12 apresentam valores inconsistentes ou com métricas de ranqueamento zeradas ou próximas de zero, indicando baixa capacidade de recomendação, apesar dos bons valores nas métricas de erro, o que indica boa capacidade de predição, mas não necessariamente boa capacidade de recomendação.

Assim, ao considerar esses quatro experimentos, vimos que o *RMSE* e *MAE* ficaram um pouco distantes dos menores valores da literatura ($RMSE < 0.8556$ [Koren et al. 2022], $MAE < 0.75$ [Marlin 2003]). Assim, podemos observar que o nosso modelo não apresenta desempenho inferior, visto que os erros são relativamente baixos. A *precision* ficou próxima de 0.199 [Sánchez and Bellogín 2019], o *recall* superou os valores da literatura ($recall > 0.434$ [de Oliveira 2019]), o *MRR* apresentou valores dentro e acima da faixa ($MRR > 0.1348$ [de Oliveira 2019]) e o *hit rate* alcançou valores próximos apenas nos experimentos baseados em perfis, enquanto nos demais grupos ficou um pouco distante ($hit\ rate < 0.73$ [He et al. 2017]).

Tabela 3. Resultados dos Experimentos

Experimento	RMSE	MAE	Precision	Recall	HitRate	MRR
1	0.6673	0.5568	0.1250	1.0000	1.0000	1.0000
2	0.6673	0.5568	0.1250	1.0000	1.0000	0.4532
3	0.7446	0.6510	0.1250	1.0000	1.0000	0.4532
4	0.7446	0.6510	0.1250	1.0000	1.0000	0.4532
5	0.6673	0.5568	0.1250	1.0000	0.8181	0.2862
6	0.6673	0.5568	0.1250	1.0000	0.8181	0.2862
7	0.7446	0.6510	0.1023	0.8181	0.8181	0.2862
8	0.7446	0.6510	0.1023	0.8181	0.8181	0.2862
9	0.3328	0.2874	0.0500	0.4000	0.3750	0.1976
10	0.3328	0.2874	0.0500	0.4000	0.3750	0.1976
11	0.3009	0.2584	0.0468	0.3750	0.3750	0.1701
12	0.3009	0.2584	0.0468	0.3750	0.3750	0.1701

4.2. Recomendação de itens para um usuário a partir da similaridade com outro usuário

Em seguida, analisamos as recomendações geradas (citadas na Seção 3.3.6). Ao analisar, percebemos que os experimentos relacionados a perfis acabaram sendo ruins, pois cada usuário possui um único perfil, ele identifica o mesmo perfil como ótimo e não consegue recomendar outro perfil, visto que o usuário não jogou essa variação.

Com isso, restaram os Experimentos 5 e 6, que apresentaram valores idênticos nas métricas de similaridade (Pearson e cosseno). Optou-se pela similaridade por cosseno, pois ela identifica padrões de interação em vez de valores absolutos.[Sanker 2025].

No Experimento 5, as recomendações são baseadas em interações reais entre usuários. O Usuário 1 e o Usuário 2, com similaridade de 0.486, possuem um item em comum (masmorra *M:30T:40G:20E:10*), com notas de 0.648 e 0.540 respectivamente, o que permite calcular uma similaridade consistente entre eles (vide Tabela 4).

A partir dessa similaridade, o sistema recomenda ao Usuário 1 a masmorra *M:40T:30G:20E:10*, que o Usuário 2 avaliou com nota 0.838, visto que foi a única avaliada pelo outro jogador. Para o Usuário 2, nenhum item é recomendado, visto que o usuário 1 apenas avaliou uma masmorra.

Diferentemente dos experimentos baseados em perfis genéricos — nos quais cada usuário possui apenas uma única interação —, o Experimento 5 utiliza múltiplas avaliações por usuário, fornecendo evidência substancial para o cálculo de similaridade e gerando recomendações explicáveis e confiáveis. Nos experimentos com perfis, usuários com perfis idênticos apresentavam similaridade igual a 1, o que faz sentido, pois cada usuário possui apenas um único perfil, enquanto os demais obtinham valores negativos, comprometendo a qualidade das recomendações.

Tabela 4. Recomendação de itens a partir da similaridade com outro usuário no Experimento 5

Item (Masmorra)	Usuário 1	Usuário 2
M:30T:10G:20E:40	0.000000	0.000000
M:30T:40G:20E:10	0.648649	0.540541
M:40T:30G:20E:10	0.000000	0.837838

Legenda: M=Mastery, T=Talk (Immersion), G=Goal (Achievement), E=Exploration (Creativity)

4.3. Recomendação de itens utilizando múltiplos usuários similares, considerando a contribuição conjunta de usuários com perfis semelhantes

Ao ranquearmos os níveis recomendados, achamos necessário entender o porquê disso. Então, visualizamos de qual usuário essa recomendação veio, ao ver o peso dele na decisão (similaridade e nota dada por ele). A Figura 1 exibe a similaridade calculada entre os usuários, enquanto na Figura 2, há a recomendação de cada nível, o qual é determinada ao calcular a similaridade do usuário alvo com outro usuário e a nota dada por esse outro usuário naquele nível. Com o acúmulo de avaliações de outros usuários, aquele nível pode se tornar mais recomendado.

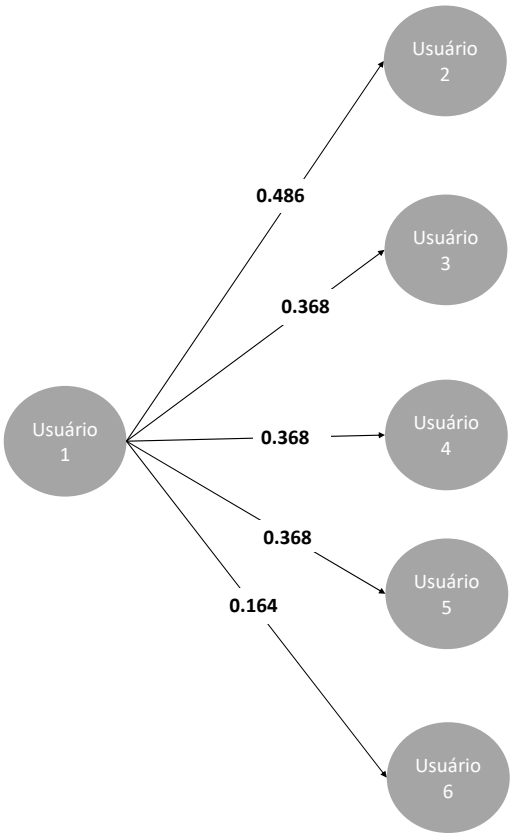


Figura 1. Relações de similaridade entre o usuário-alvo e demais usuários

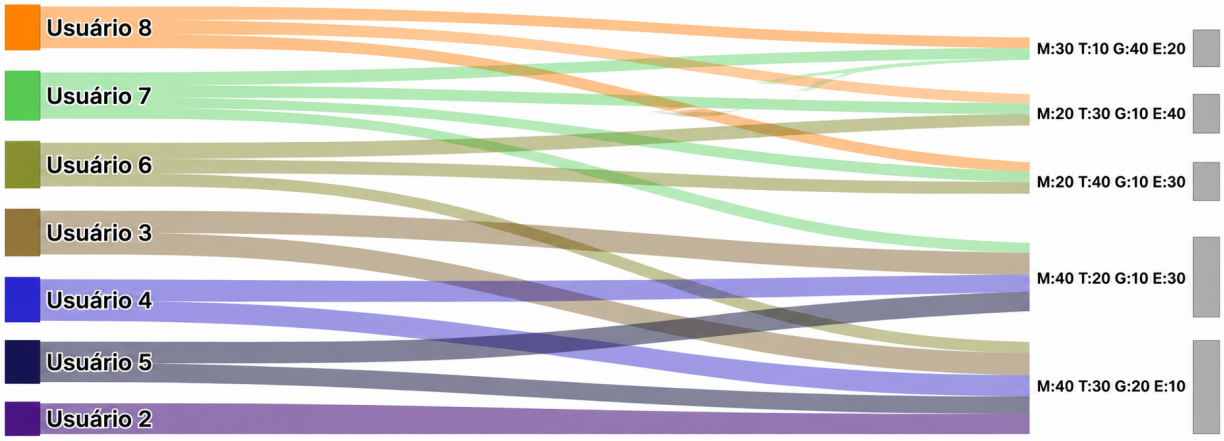


Figura 2. Ponderação dos itens recomendados para o usuário-alvo a partir dos pesos calculados (similaridade e nota da avaliação). Legenda: M=Mastery, T=Talk (Immersion), G=Goal (Achievement), E=Exploration

4.4. Recomendação de itens semelhantes a um item de referência, com base na similaridade entre itens

Em seguida, analisamos as recomendações item por item. Nisso, a similaridade era 1 nos casos de masmorras com mesma configuração. E também, recomendaram outras

configurações a partir da original, o que pode ser visto na Figura 3.

Por exemplo, para a masmorra *M:10T:40G:30E:20*, o sistema recomendou itens com configurações similares, como *M:20T:40G:10E:30* (similaridade 0.400) e *M:10T:20G:40E:30* (similaridade 0.303), ambas com similaridade altas ao considerar todos os valores. Isso demonstra que o sistema é capaz de identificar padrões de preferência do usuário e recomendar variações coerentes das masmorras avaliadas, mantendo a essência das características preferidas.

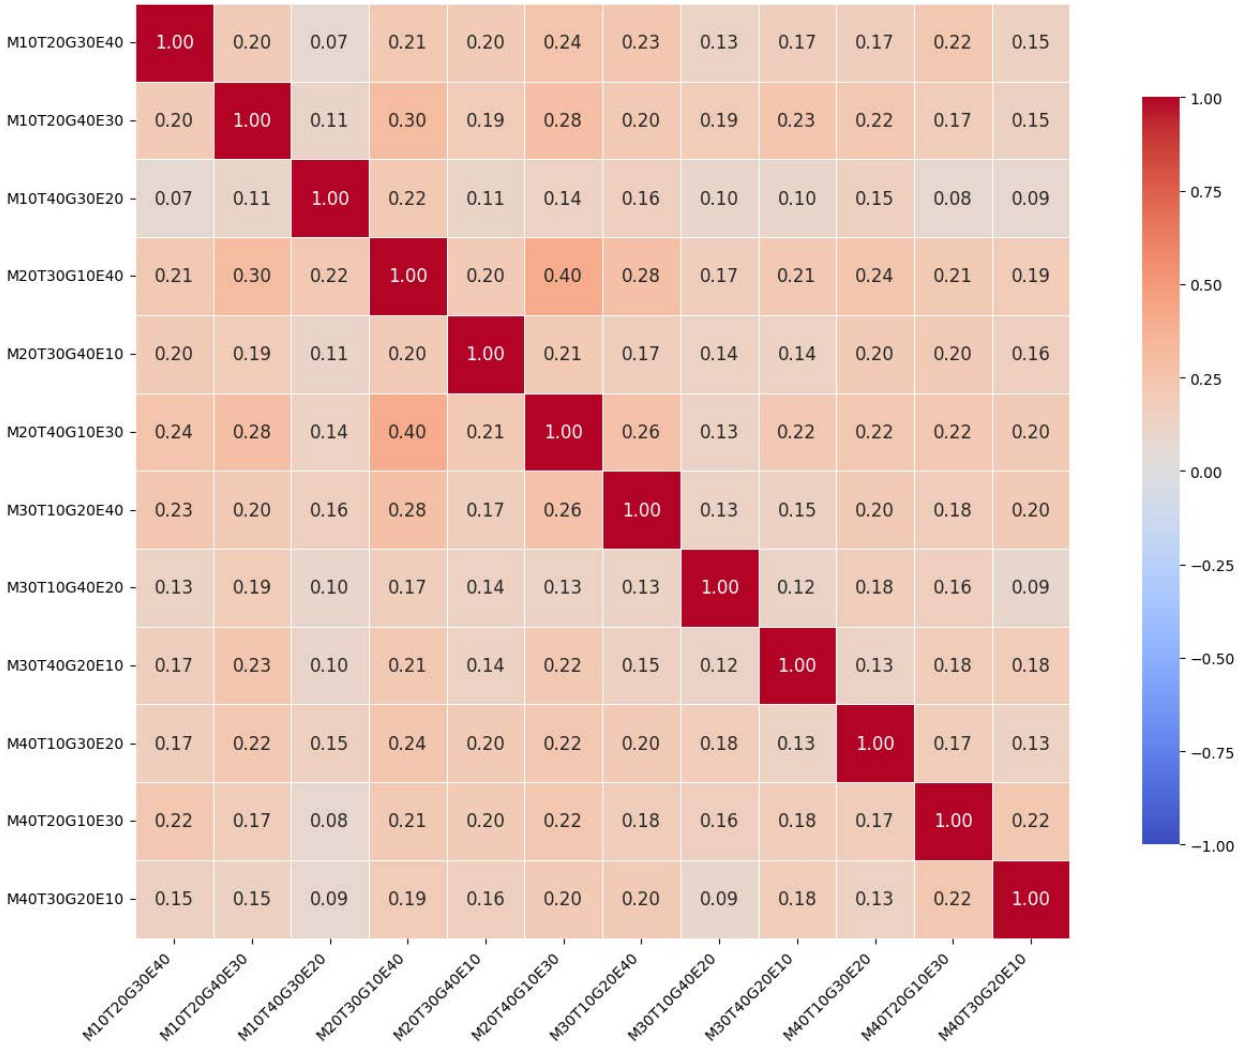


Figura 3. Matriz de Similaridade entre Itens (masmorras). Legenda: M=Mastery, T=Talk (Immersion), G=Goal (Achievement), E=Exploration

4.5. Recomendação híbrida

Ao tentar realizar a recomendação híbrida, observou-se aumento nas similaridades entre os itens, porém uma redução nas similaridades entre os usuários. O *RMSE* aumentou de 0.6673 para 0.9623 (aumento de 44.21%) e o *MAE* aumentou de 0.5568 para 0.8727 (aumento de 56.74%), enquanto as demais métricas permaneceram estáveis. Além disso, as similaridades diminuíram (15.82% ao comparar o Usuário 1 e o Usuário 2), tornando o modelo mais adequado, embora isso comprometa a precisão numérica das

recomendações [Sanker 2025]. Por não ter sido observada uma vantagem significativa, mantemos a recomendação sem ser híbrida.

4.6. Recomendações mais segmentadas

Assim, selecionamos o Experimento 5, que corresponde ao nível do jogo com recomendações agregadas por exploração.

Na Tabela 5, identificamos um intervalo entre 15,3 e 17,2 salas e uma variação de 3 a 5 chaves/fechaduras recomendadas para o Usuário 1.

Tabela 5. Recomendações Agregadas por Estrutura da Masmorra

Masmorra	Média de Salas	Média de Chaves/Fechaduras
M:40T:30G:20E:10	15.3	3.00
M:20T:40G:10E:30	17.2	4.00
M:30T:10G:40E:20	17.2	4.00
M:20T:30G:10E:40	17.0	5.00
M:40T:20G:10E:30	17.0	4.00

Ao analisar a Tabela 6, observa-se que um usuário não apresenta um perfil exclusivamente dominante, mas sim uma combinação de diferentes preferências de missão. O Usuário 1 demonstra maior inclinação para *Mastery* e *Immersion*, com destaque para *Mastery*, que obteve a maior média entre as recomendações (28,92).

Além disso, nota-se que *Creativity* apresentou um valor muito próximo ao de *Immersion*, sendo apenas 1,22% superior, o que indica um equilíbrio entre essas dimensões.

Tabela 6. Recomendações Agregadas por Preferências de Missões

Masmorra	A% (Achievement)	C% (Creativity)	I% (Immersion)	M% (Mastery)
M:40T:30G:20E:10	15.4	11.5	26.9	46.2
M:20T:40G:10E:30	8.8	26.5	44.1	20.6
M:30T:10G:40E:20	36.4	29.5	13.6	20.5
M:20T:30G:10E:40	6.7	40.0	37.8	15.6
M:40T:20G:10E:30	8.3	44.3	16.7	41.7

Na Tabela 7, observamos que não há variação no número de *NPCs* definidos. No entanto, foi possível identificar uma taxa de interações com esses personagens. Além disso, ppercebe-se que, para o Usuário 1, o ideal é receber recomendações com taxa de interação acima de 433,3%, embora valores em torno de 94,7% já sejam suficientes para agradá-lo.

Na Tabela 8, os níveis foram definidos a partir da dificuldade, calculada por meio de uma média ponderada. Essa média considera o número de derrotas e vitórias contra inimigos, a quantidade de vida perdida e o total de inimigos enfrentados.

O maior peso foi atribuído ao número de derrotas, seguido pela quantidade de vida perdida. Por fim, o número de vitórias e o total de inimigos receberam menor peso na composição da dificuldade.

Tabela 7. Recomendações Agregadas por NPCs

Masmorra	Média de NPCs	Interagidos	Taxa Interação %
M:40T:30G:20E:10	3.0	13.0	433.3
M:20T:40G:10E:30	3.0	15.0	500.0
M:30T:10G:40E:20	3.0	12.0	400.0
M:20T:30G:10E:40	3.0	21.8	726.7
M:40T:20G:10E:30	3.0	2.8	94.4

Tabela 8. Recomendações Agregadas por Dificuldade

Masmorra	Média de Inimigos	Média de Vitórias	Vida perdida	Média de Derrotas	Dificuldade
M:40T:30G:20E:10	49.7	25.7	8.2	0.67	0.47
M:20T:40G:10E:30	24.6	18.4	3.6	0.0	0.14
M:30T:10G:40E:20	23.7	20.9	5.4	0.67	0.33
M:20T:30G:10E:40	15.0	12.8	2.8	0.00	0.10
M:40T:20G:10E:30	29.5	18.2	7.3	0.67	0.43

4.7. Recomendações a partir das tabelas

Com esses valores em mente, realizamos a recomendação de níveis, buscando aqueles que mais se aproximassem dos parâmetros definidos, ou seja, níveis cujas características estivessem dentro dos intervalos previamente observados.

No caso da estrutura, todas as variáveis foram consideradas. Para o perfil, priorizamos níveis cujos percentuais estivessem mais próximos dos valores identificados para o usuário. Em relação aos *NPCs*, focamos em encontrar uma taxa de interação semelhante. Já para os inimigos, buscamos níveis cujos valores e desempenho do jogador se enquadrassem nos padrões observados, além de considerar a dificuldade previamente calculada.

Na Tabela 9, são apresentados os níveis recomendados que mais se aproximam das configurações obtidas. Buscamos os níveis a partir do ranqueamento da tabela anterior. Para o caso da dificuldade, classificamos valores abaixo de 0,3 como fáceis; entre 0,3 e 0,5 como médios; entre 0,5 e 0,7 como difíceis; e acima de 0,7 como muito difíceis, além de considerar o intervalo dos valores.

Podemos perceber que nenhum dos níveis atendeu 100% dos requisitos. Porém, observa-se que, entre os níveis já recomendados anteriormente, eles atendem apenas aos *NPCs*, e novos níveis não atendem a esses parâmetros. Ainda assim, nota-se que apenas um nível conseguiu atender três dos quatro requisitos (*M:20T:30G:40E:10*).

Em seguida, fizemos uma recomendação de novas configurações a partir dos intervalos determinados, os quais foram definidos dentro dos ranges estabelecidos. Nesse contexto, uma configuração resultante foi composta por um total de 16 salas, com 4 chaves/fechaduras, 32 inimigos e uma configuração das missões baseada no perfil (A% / C% / I% / M%): 15,1% / 28,2% / 27,8% / 28,9%.

5. Conclusões

Com o desenvolvimento deste trabalho, foi possível identificar diversas contribuições relevantes. Entre eles, observa-se que a avaliação do usuário é um método mais confiável para recomendação, visto que é difícil inferir com precisão o comportamento do usuário [Ricci et al. 2010].

Tabela 9. Recomendações de Masmorras à partir das Agregações

Masmorra	Estrutura	Perfil	NPCs	Dificuldade
M:40T:30G:20E:10	Não	Não	Sim	Não
M:20T:40G:10E:30	Não	Não	Sim	Não
M:30T:10G:40E:20	Não	Não	Sim	Não
M:20T:30G:10E:40	Não	Não	Sim	Não
M:40T:20G:10E:30	Não	Não	Sim	Não
M:20T:30G:40E:10	Sim	Sim	Não	Sim
M:30T:40G:20E:10	Sim	Não	Não	Não
M:40T:10G:30E:20	Sim	Não	Não	Não
M:30T:10G:20E:40	Sim	Não	Não	Não
M:10T:20G:40E:30	Sim	Não	Não	Sim
M:10T:40G:30E:20	Sim	Não	Não	Sim
M:10T:20G:30E:40	Sim	Não	Não	Sim

Modelos híbridos, por sua vez, tendem a herdar parte dessas limitações relacionadas ao comportamento dos usuários, especialmente quando dependem de percentuais de influência previamente definidos.

Também foi possível observar que o banco de dados utilizado apresenta baixa diversidade, uma vez que não contempla todas as variações de perfis e que os jogadores não exploraram uma ampla variedade de masmorras. Isso limita a qualidade do cálculo de similaridade, uma vez que a geração de combinações distintas foi reduzida em relação ao espaço total possível de configurações.

Ainda assim, foi possível perceber a influência dos perfis, uma vez que as recomendações não se distanciavam significativamente das variações esperadas. Isso sugere que esse fator poderia ser refinado, incorporando o perfil de forma mais estruturada no processo de recomendação. Em vez de apenas utilizá-lo como um componente de ponderação, seria interessante empregá-lo como um diferenciador explícito, permitindo a separação de tipos de perfis e uma análise mais clara dentro de cada categoria. Também seria possível definir métricas específicas para avaliar se as recomendações se mantêm dentro ou fora de determinado perfil.

Nesse sentido, poderia ser adotado um método híbrido que priorize o perfil do usuário, mas sem ignorar outros fatores relevantes. Assim, compreender melhor a influência do perfil torna-se fundamental para aprimorar a qualidade das recomendações.

Além disso, o banco de dados deveria ser aprimorado para aumentar sua diversidade, permitindo uma avaliação mais ampla do modelo. Outras abordagens de recomendação também poderiam ser exploradas, assim como um maior número de comparações, a fim de verificar com mais robustez se os resultados permanecem consistentes dentro de diferentes cenários.

Por fim, fica evidente que os tipos de recomendação pertencem a contextos distintos [Ricci et al. 2010]. Por exemplo, recomendações agregadas fazem mais sentido quando utilizadas para sugerir novas configurações com base em tendências gerais, em vez de buscar similaridades diretas. Esse tipo de abordagem também pode ser útil para

entender preferências gerais do usuário, ajudando no desenvolvimento ou atualizações dos jogos. Já métodos baseados em similaridade são mais adequados para recomendações individualizadas, apesar de sua utilidade no contexto de desenvolvimento.

Em suma, este trabalho reforça a importância de sistemas de recomendação no contexto de perfilamento em jogos, ao investigar sua influência e contribuir para a personalização de conteúdo de forma mais adaptativa.

Referências

Balda, H. D. F. (2020). Improvement of player experience through dynamic difficulty adjustment using behavioral patterns and machine learning. Diss. (graduação), Tokyo University of Technology.

Carneiro, N., Souza, K., Sidarta, I., Pereira, G., Mendonça, G., and Darin, T. (2021). To each their own (type): A systematic mapping study on player's motivations, behavior, and personality characteristics. In *Proceedings of the XX Brazilian Symposium on Human Factors in Computing Systems*, IHC '21, New York, NY, USA. Association for Computing Machinery.

Carvalho, L. A. M. a. C. and Macedo, H. T. (2013). Users' satisfaction in recommendation systems for groups: an approach based on noncooperative games. In *Proceedings of the 22nd International Conference on World Wide Web*, WWW '13 Companion, page 951–958, New York, NY, USA. Association for Computing Machinery.

Chanel, G. and Lopes, P. (2020). User evaluation of affective dynamic difficulty adjustment based on physiological deep learning. In *Augmented Cognition. Theoretical and Technological Approaches*, pages 3–23, Cham. Springer International Publishing.

Charity, M., Bhartia, Y., Zhang, D., Khalifa, A., and Togelius, J. (2023). A preliminary study on a conceptual game feature generation and recommendation system. *arXiv preprint arXiv:2308.13538*.

Chen, Y.-C., Hui, L., and Thaipisutikul, T. (2021). A collaborative filtering recommendation system with dynamic time decay. *J. Supercomput.*, 77(1):244–262.

Chrysafiadi, K., Kamitsios, M., and Virvou, M. (2023). Fuzzy-based dynamic difficulty adjustment of an educational 3d-game. *Multimedia Tools and Applications*, 82(18):27525–27549.

de Lima, E. S., Silva, B. M., and Galam, G. T. (2022). Adaptive virtual reality horror games based on machine learning and player modeling. *Entertainment Computing*, 43:100515.

de Oliveira, D. S. (2019). Sistema de recomendação baseado em filtragem colaborativa em uma base de dados de feedback implícito. Master's thesis, Centro de Informática, Universidade Federal de Pernambuco, Recife. Trabalho de Graduação (Bacharel em Ciência da Computação).

Global Growth Insights (2024). Video game market size, share, growth, and industry analysis, by types (kids, adults), applications (action, adventure and role playing, arcade, strategy, simulation, driving, other), and regional insights and forecast to 2035. `https://www.globalgrowthinsights.com/pt/market-reports/video-game-market-107798`. Acesso em: 16 mar. 2026.

Grcar, M. (2004). User profiling: Collaborative filtering. In *Proceedings of SIKDD 2004 at Multiconference IS*, pages 75–78.

Hannon, J., Bennett, M., and Smyth, B. (2010). Recommending twitter users to follow using content and collaborative filtering approaches. In *Proceedings of the Fourth ACM Conference on Recommender Systems*, RecSys '10, page 199–206, New York, NY, USA. Association for Computing Machinery.

He, X., Liao, L., Zhang, H., Nie, L., Hu, X., and Chua, T.-S. (2017). Neural collaborative filtering. In *Proceedings of the 26th International Conference on World Wide Web*, WWW '17, page 173–182, Republic and Canton of Geneva, CHE. International World Wide Web Conferences Steering Committee.

Hookham, G. and Nesbitt, K. (2019). A systematic review of the definition and measurement of engagement in serious games. pages 1–10.

Kline, R. B. (2016). *Principles and Practice of Structural Equation Modeling*. The Guilford Press, New York, 4 edition.

Koren, Y., Rendle, S., and Bell, R. (2022). *Advances in Collaborative Filtering*, pages 91–142. Springer US, New York, NY.

Liapis, A., Yannakakis, G. N., Nelson, M. J., Preuss, M., and Bidarra, R. (2019). Orchestrating game generation. *IEEE Transactions on Games*, 11(1):48–68.

Liapis, A., Yannakakis, G. N., and Togelius, J. (2014). Computational game creativity. In *Proceedings of the fifth International Conference on Computational Creativity*.

Marlin, B. (2003). Modeling user rating profiles for collaborative filtering. In *Proceedings of the 17th International Conference on Neural Information Processing Systems*, NIPS'03, page 627–634, Cambridge, MA, USA. MIT Press.

Martins, B. d. H. (2021). Assessing game player profiles through agent-based simulation.

McNee, S. and Riedl, J. (2006). Being accurate is not enough: How accuracy metrics have hurt recommender systems. pages 1097–1101.

Orhan Göksün, D. and Gürsoy, G. (2019). Comparing success and engagement in gamified learning experiences via kahoot and quizizz. *Computers & Education*, 135.

Pereira, L., Teoi, Y., and Toledo, C. (2024). Towards evaluating a procedural content orchestrator gameplay data to differentiate user profiles. In *Anais do III Workshop sobre Interação e Pesquisa de Usuários no Desenvolvimento de Jogos*, pages 75–86, Porto Alegre, RS, Brasil. SBC.

Pereira, L., Viana, B., and Toledo, C. (2022). A system for orchestrating multiple procedurally generated content for different player profiles. *IEEE Transactions on Games*, PP:1–11.

Pereira, L. T., Teoi, T. Y., and Toledo, C. F. M. (2025). Evaluating a procedural content orchestrator gameplay data and classifying user profiles. *Journal on Interactive Systems*, 16(1):490–504.

Pinto, M. A. G. (2021). *Sistema Híbrido de Recomendação de Produtos com Uso de Filtros Colaborativos e Números Fuzzy*. Tese de doutorado, Pontifícia Universidade Católica do Rio de Janeiro, Rio de Janeiro, Brazil.

Ricci, F., Rokach, L., and Shapira, B. (2010). *Recommender Systems Handbook*, volume 1-35, pages 1–35.

Rosa, M. P., Castanho, C., Silva, T., Sarmet, M., and Jacobi, R. (2023). *Dynamic Difficulty Adjustment by Performance and Player Profile in Platform Game*, pages 3–16.

Rymarczyk, P., Golabek, P., Sylwia, and Rzemieniak, M. (2021). Profiling and segmenting clients with the use of machine learning algorithms. *EUROPEAN RESEARCH STUDIES JOURNAL*, XXIV:513–522.

Sanker, A. P. (2025). Filtragem colaborativa: Seu guia para recomendações mais inteligentes. DataCamp. Acesso em: 14 de abril de 2026.

Santos, C. P., Hutchinson, K., Khan, V.-J., and Markopoulos, P. (2019). Profiling personality traits with games. *ACM Trans. Interact. Intell. Syst.*, 9(2–3).

Schrader, C. (2022). *Serious Games and Game-Based Learning*, pages 1–14. Springer Singapore, Singapore.

Su, X. and Khoshgoftaar, T. M. (2009). A survey of collaborative filtering techniques. *Advances in Artificial Intelligence*, 2009(1):421425.

Sánchez, P. and Bellogín, A. (2019). Building user profiles based on sequences for content and collaborative filtering. *Information Processing Management*, 56(1):192–211.

Teoi, T., Pereira, L., and Toledo, C. (2024). Towards adapting a content orchestrator to a different gamegenre: Generating levels, rules, and narrative for diverse player profiles from a top-down adventure to a 2d platformer. In *Anais do XXIII Simpósio Brasileiro de Jogos e Entretenimento Digital*, pages 396–415, Porto Alegre, RS, Brasil. SBC.

Vang, C. (2022). The impact of dynamic difficulty adjustment on player experience in video games. *Scholarly Horizons: University of Minnesota, Morris Undergraduate Journal*, 9(1):Article 7.

Yee, N. and Ducheneaut, N. (2018). Gamer motivation profiling: uses and applications. In Drachen, A., Mirza-Babaei, P., and Nacke, L., editors, *Games User Research*. Oxford University Press.

Zhou, X., Li, F., Hu, J., and Liang, J. (2025). A customer profiling method for personalized service in retail pharmacies. In *Proceedings of the 2025 6th International Conference on Computer Information and Big Data Applications*, CIBDA '25, page 1082–1086, New York, NY, USA. Association for Computing Machinery.