Filtragem Colaborativa para Perfilamento de Jogadores em Jogos Digitais

Pedro G. Gonçalves

Instituto de Geociências e Ciências Exatas – Universidade Estadual Paulista (UNESP)
Rio Claro – SP – Brazil

pedro.g.goncalves@unesp.br

Abstract. *One of the main challenges in the digital games industry is understanding players' preferences in order to provide experiences that promote high levels of immersion and satisfaction. In this work, a content recommendation approach was developed based on data obtained from matches of different players. To this end, distinct collaborative filtering approaches were implemented and compared. The results made it possible to identify the best-performing model, demonstrating its suitability for personalizing the player's experience.*

Resumo. *Um dos principais desafios da indústria de jogos digitais é compreender as preferências dos jogadores a fim de oferecer experiências que promovam elevados níveis de imersão e satisfação. Neste trabalho, foi desenvolvida uma abordagem de recomendação de conteúdo com base em dados provenientes de partidas de diferentes jogadores. Para isso, foram implementadas e comparadas distintas abordagens de filtragem colaborativa. Os resultados obtidos possibilitaram a identificação do modelo com melhor desempenho, evidenciando sua adequação à personalização da experiência do jogador.*

1. Introdução

A indústria de jogos digitais, que projeta expandir de US$ 25,5 bilhões para US$ 37,74 bilhões até 2035 [Global Growth Insights 2024], apresenta o desafio de atender a públicos diversificados. Para isso, compreender o comportamento e as preferências do jogador torna-se fundamental para produzir conteúdos que aumentem sua imersão e satisfação [Martins 2021, Balda 2020].

Assim, diversas técnicas são utilizadas, como heurísticas, lógica *fuzzy*, filtragem colaborativa e algoritmos de Aprendizado de Máquina (AM) e Aprendizado Profundo (AP) [Rosa et al. 2023, Hannon et al. 2010, Chrysafiadi et al. 2023, Chanel and Lopes 2020, de Lima et al. 2022, Sanker 2025], com o objetivo de promover a personalização, que pode ser realizada por meio de técnicas de recomendação baseadas em dados de comportamento, desempenho ou avaliação do jogador [Sanker 2025, Balda 2020].

Dentre essas técnicas, a filtragem colaborativa contribui ao identificar jogadores semelhantes com base em seus padrões de interação, possibilitando a inferência de preferências e comportamentos de um jogador a partir dos dados de seus vizinhos mais próximos. [Sanker 2025, Grcar 2004].

Dessa forma, padrões observados em grupos de jogadores com perfis semelhantes podem ser utilizados para estimar características de novos jogadores, mesmo na

ausência de dados completos. Esse processo viabiliza a associação desses jogadores a perfis representativos, possibilitando, assim, a recomendação adequada de conteúdo [Sanker 2025, Chen et al. 2021].

Com base nisso, este projeto investigou abordagens para recomendação de conteúdo utilizando a filtragem colaborativa como mecanismo de personalização. Para isso, foi utilizada uma base de dados composta por informações de jogadores e partidas, coletada no contexto *Overlord*, um orquestrador de Geração Procedural de Conteúdo [Pereira et al. 2022] e disponibilizada no trabalho [Pereira et al. 2024].

Essa base é composta por aproximadamente 119 instâncias de gameplay (registros de sessões de jogo), posteriormente expandida para mais de 1000 instâncias por meio de técnicas estatísticas de aumento de dados (*data augmentation*), conforme metodologia validada na literatura [Pereira et al. 2025]. Esse procedimento visou mitigar os efeitos do tamanho reduzido da amostra original e permitir uma avaliação mais robusta dos modelos. Ela reúne dados relacionados aos níveis gerados (masmorras com quebra-cabeças e posicionamento de inimigos), narrativa (missões) e regras (atributos e mecânicas dos inimigos), permitindo a extração de padrões de comportamento e desempenho.

A partir desses dados, buscou-se identificar e agrupar jogadores em diferentes perfis de jogabilidade, possibilitando a recomendação de níveis mais adequados, bem como a indicação separada de parâmetros como dificuldade de inimigos e preferências por missões.

Com os dados estruturados, foram implementados e comparados três modelos: a filtragem baseada em item, na qual é considerada a avaliação do nível pelo jogador; a filtragem baseada no usuário, a partir de dados de seu comportamento na partida; e um modelo misto de ambos [Hannon et al. 2010, Su and Khoshgoftaar 2009, Koren et al. 2022]. Para isso, foram utilizadas as medidas de similaridade de cosseno e correlação de Pearson para quantificar a semelhança entre usuários [Sanker 2025].

A avaliação da filtragem colaborativa foi realizada por meio de métricas de predição *RMSE* e *MAE*, comparando as notas previstas com as notas reais no conjunto de teste. Para isso, adotou-se a divisão treino-teste, utilizando o conjunto de treino para aprender os padrões de similaridade entre jogadores e itens, enquanto o conjunto de teste foi utilizado para validação das predições. Adicionalmente, foram utilizadas métricas de precisão, *recall*, *hit rate* e *MRR* para avaliar a qualidade das recomendações geradas [Su and Khoshgoftaar 2009, Chen et al. 2021].

As principais contribuições deste trabalho são: (i) fornecer, por meio dos resultados obtidos, uma análise comparativa fundamentada dos pontos fortes e das limitações das abordagens investigadas, contribuindo para a área de jogos sérios e entretenimento [Schrader 2022]; (ii) oferecer subsídios teóricos e práticos para o desenvolvimento de sistemas de recomendação e adaptação mais robustos em jogos digitais; e (iii) contribuir para a área de IA ao investigar a aplicação de filtragem colaborativa na modelagem do comportamento de jogadores, avaliando sua capacidade de perfilamento e recomendação em ambientes interativos.

O artigo está organizado da seguinte forma: a Seção 2 apresenta os trabalhos relacionados sobre a adaptação de jogos; a Seção 3 descreve a metodologia; a Seção 4 discute os resultados; e a Seção 5 apresenta as conclusões.

2. Trabalhos Relacionados

Esta seção estabelece as bases teóricas e metodológicas deste estudo. Inicialmente, são apresentados conceitos relacionados a jogos digitais; em seguida, abordam-se aspectos referentes ao bancos de dados; por fim, discute-se a Filtragem Colaborativa.

2.1. Facetas Criativas dos Jogos

Jogos digitais possuem diversas facetas que contribuem para sua concepção; portanto, alguns autores consideram necessário defini-las de forma estruturada, a fim de organizar o processo de criação. Dessa forma, foram definidas seis facetas criativas: áudio, níveis, narrativa, regras, visuais e jogabilidade [Liapis et al. 2014, Liapis et al. 2019].

Áudio refere-se a qualquer elemento sonoro, como vozes e música. Níveis correspondem à elementos que o jogador deve superar, como ambientes, objetos ou progressão. Narrativa é a história do personagem, do mundo e as missões. Regras são os parâmetros, o estado ou condições. Visuais engloba texturas, aparências e efeitos visuais. Por fim, jogabilidade refere-se aos aspectos de simulação ou testes.

Essa definição fornece uma nomenclatura que permite uma melhor organização e análise dos elementos do jogo, podendo servir como base para o design de jogos ao contribuir para a identificação de perfis de jogadores e características de grupo [Carneiro et al. 2021, Martins 2021], mesmo que jogos como *Dispatch*[1] apresentem essa ambiguidade, na qual a jogabilidade interfere na narrativa e nos níveis.

2.2. Overlord

O *Overlord* é um orquestrador de conteúdo responsável por coordenar três facetas criativas do jogo: (i) *níveis*, que produz masmorras compostas por salas contendo inimigos, NPCs e itens; (ii) *regras*, responsável por selecionar os parâmetros dos inimigos, tais como saúde, velocidade de movimento e dano causado; e (iii) *narrativa*, que define o *template* da missão de acordo com o perfil do jogador [Pereira et al. 2022].

O orquestrador considera o perfil do jogador para pós-processar o conteúdo gerado pelos diferentes sistemas, sendo assim adaptativo. Sua capacidade foi testada, obtendo resultados positivos para a diversão e a adaptação ao perfil [Pereira et al. 2022, Teoi et al. 2024].

Para este trabalho, foram utilizados dados coletados de um jogo, orquestrado pelo Overlord, no qual foram testadas e descritas as experiências dos jogadores nos estudos supracitados.

2.3. Perfis

Para a adaptação de conteúdo, por meio do perfilamento, adotou-se a definição conhecida como os quatro fatores de motivação [Yee and Ducheneaut 2018]: **A**chievement: refere-se a jogadores que priorizam conquistas e fortalecimento de seus personagens, **C**reativity caracteriza jogadores que valorizam personalização e exploração, **I**mmersion caracteriza jogadores interessados na narrativa e em incorporar seu personagem e **M**astery representa jogadores motivados por desafios, resolução de problemas e experiências estratégicas.

[1]Dispatch. Disponível em: https://store.steampowered.com/app/2592160/Dispatch/. Acesso em: 5 maio 2026.

Cada fator recebe um valor único entre 1 e 4, que representa sua influência, sendo 1 o mínimo e 4 o máximo. Por exemplo, um jogador do tipo **Mastery** receberia valor 4 para esse fator, enquanto os demais variariam entre 1 e 3. Essa é a representação utilizada pelo Overlord e, neste trabalho, ela foi mantida para facilitar o entendimento e a comparação dos resultados [Pereira et al. 2022].

2.4. Filtragem Colaborativa

A Filtragem Colaborativa é uma das técnicas de recomendação mais consolidadas para predizer com precisão os interesses dos usuários. Atualmente, ela é principalmente categorizada em filtragem baseada em itens e filtragem baseada em usuários [Chen et al. 2021].

A filtragem baseada em usuários identifica comportamentos semelhantes entre os usuários e recomenda itens que usuários com perfis parecidos apreciaram. Por sua vez, a filtragem baseada em itens recomenda produtos com base nas interações anteriores do próprio usuário, sugerindo itens similares aos que ele gostou. Esses modelos são complementares e, por isso, sistemas modernos os integram em abordagens híbridas para melhorar a precisão das recomendações [Sanker 2025].

Para viabilizar a recomendação por meio da Filtragem Colaborativa, a similaridade entre usuários ou itens pode ser calculada por diferentes métricas, tais como a similaridade do cosseno e a correlação de Pearson [Chen et al. 2021].

Uma das principais características dessa técnica é a capacidade de identificar relações entre itens que não possuem similaridade de conteúdo, mas que estão conectados por meio dos grupos de usuários que os utilizam. Assim, esses grupos representam perfis específicos de usuários [Grcar 2004]. Dessa forma, a Filtragem Colaborativa pode ser aplicada neste trabalho para identificar perfis de usuários e, consequentemente, recomendar conteúdos mais adequados às preferências de cada usuário, contribuindo para a personalização do sistema de recomendação.

3. Metodologia

3.1. Tecnologia

O sistema de recomendação baseado em Filtragem Colaborativa utilizando a linguagem de programação *Python*, no ambiente de desenvolvimento *Google Colab*[2].

3.2. Coleta das métricas de jogabilidade

As métricas de comportamento do jogador durante a partida foram coletadas por meio de registros (*logs*) gerados automaticamente ao longo da execução do jogo. Cada *log* é armazenado quando o jogador conclui a fase ou quando encerra a partida.

Foram registrados dados relacionados ao desempenho do jogador, à sua interação com os elementos da masmorra e ao estado final da partida, incluindo métricas de combate, exploração, progressão e conclusão da sessão.

Esses dados foram coletados utilizando variáveis inteiras e booleanas, permitindo a representação de comportamentos e estados de resultado da partida.

[2]Google Colab. Disponível em: https://colab.research.google.com/. Acesso em: 6 maio 2026.

3.3. Coleta de dados de perfil dos jogadores

A coleta dos dados relacionados ao perfil foi realizada por meio da aplicação de um questionário na primeira vez em que o jogador acessa o jogo. O instrumento foi baseado e adaptado a partir do conceito dos quatro fatores de motivação propostos na literatura [Yee and Ducheneaut 2018], com o objetivo de inferir o perfil motivacional do jogador.

O questionário é composto por doze itens, sendo, distribuídos da seguinte forma: duas questões relacionadas à experiência geral com jogos, três questões associadas ao perfil de Mastery, duas questões para cada um dos demais perfis e uma questão adicional, utilizada como fator de penalização para perfis não relacionados ao Mastery.

Com base nas respostas, são calculados escores para cada um dos quatro fatores de motivação. Essas equações combinam as respostas dos jogadores para estimar a intensidade de cada motivação [Pereira et al. 2022].

Após o cálculo dos escores, cada jogador recebe uma representação de perfil baseada em pesos de 1 a 4 para cada fator de motivação. O maior valor recebe o maior peso da escala, enquanto os demais são atribuídos de forma decrescente até o menor peso.

3.4. Procedimento

Com base no conhecimento das informações presentes no banco de dados, iniciou-se a etapa de implementação. O processo experimental foi estruturado em seis etapas: (i) divisão dos dados, (ii) aumento de dados, (iii) tipo de filtragem, (iv) cálculo de similaridade, (v) validação do modelo e (vi) recomendações

3.4.1. Divisão dos dados

O conjunto de dados foi particionado em subconjuntos de treino e teste utilizando a estratégia como *Leave-One-Out (LOO)*, método em que uma interação é removida para teste enquanto as demais permanecem no treinamento, validada na literatura [de Oliveira 2019, Ricci et al. 2010].

3.4.2. Aumento de dados

Em seguida, aplicou-se aumento de dados exclusivamente ao conjunto de treino, prática recomendada na literatura para evitar vazamento de informação e preservar a validade da avaliação experimental [Ricci et al. 2010].

Dessa forma, foi adotado o melhor cenário aplicado a este conjunto de dados, no qual os melhores resultados foram obtidos com uma ampliação de dez vezes em relação ao baseline. Esse cenário inclui as 119 métricas originais de gameplay, aumentadas seis vezes com ruído (gerando 714 novas instâncias), além de 119 novas instâncias obtidas a partir de quatro diferentes configurações de escalonamento, que consistem na multiplicação das instâncias originais por 0,9; 0,95; 1,05 e 1,1 (totalizando 476 novas instâncias) [Pereira et al. 2025].

Após o processo de aumento, o conjunto de treinamento passou a conter 1309 instâncias de dados de gameplay e apresentou uma acurácia média de quase 95%, com um desvio padrão de 0,031 entre os folds [Pereira et al. 2025].

3.4.3. Configuração de entrada

Foram definidas três abordagens de filtragem colaborativa: (i) baseada em usuário, (ii) baseada em itens e (iii) um modelo híbrido, combinando as duas estratégias anteriores.

Todas as abordagens utilizam três entradas principais para a construção da matriz usuário-item: a coluna *user*, responsável por identificar cada usuário do sistema e permitir o agrupamento de suas interações, viabilizando a construção de um perfil individual de preferências; a coluna *item*, que representa os itens (conteúdos) que tiveram interações de comportamento ou avaliação dos usuários, relacionando cada interação ao objeto específico do sistema de recomendação; e o campo *weight*, utilizado para modelar a preferência do usuário a partir de avaliações ou comportamento, servindo como base para o cálculo de similaridades e para a geração de recomendações.

A coluna *user* foi definida, em todos os casos, a partir do identificador único do jogador presente no conjunto de dados. As demais colunas, no entanto, foram construídas a partir de diferentes estratégias de representação, conforme a abordagem adotada.

Para a definição do campo *weight*, foram avaliadas três estratégias distintas. Na abordagem baseada em itens, utilizou-se a coluna referente ao formulário pós-jogo, que representa a avaliação explícita do usuário após a experiência na masmorra. Já na abordagem baseada em comportamento, o valor de *weight* foi calculado a partir da média de métricas que representam o desempenho do jogador em quatro facetas da criatividade: taxa de sucesso (A), sobrevivência (I), combate (M) e progressão no mapa (C). Essa estratégia busca capturar preferências implícitas a partir do comportamento observado. Na abordagem híbrida, o valor final de *weight* foi obtido por meio da média entre os valores gerados pelas abordagens baseada em itens e baseada em comportamento.

Além disso, para todas as abordagens, foram consideradas três configurações distintas para a coluna *item*: (i) uma representação baseada no perfil estrutural da masmorra (por exemplo, A=4, C=2, M=1, I=3); (ii) uma representação agregada da masmorra a partir da identificação do nível, considerando a proporção estimada de seus elementos característicos (por exemplo, Mastery:20, Talk (Immersion):30, Goal (Achievement):10, Exploration (Creativity):40); e (iii) uma representação granular, composta por atributos quantitativos que descrevem diretamente os elementos estruturais da masmorra, como número de salas, chaves, portas e cadeados.

3.4.4. Cálculo de similaridade

Todas as abordagens de filtragem colaborativa foram submetidas, separadamente, ao cálculo de similaridade por cosseno e à correlação de Pearson.

A similaridade por cosseno calcula o cosseno do ângulo entre dois vetores [Chen et al. 2021], sendo definida como:

$$similaridade(A, B) = \cos(\theta) = \frac{\sum_{i=1}^{n} A_i B_i}{\sqrt{\sum_{i=1}^{n} A_i^2}\sqrt{\sum_{i=1}^{n} B_i^2}}$$

em que A e B representam os vetores de usuários ou itens, e A_i e B_i correspondem

aos valores associados a cada dimensão do vetor.

Já a correlação de Pearson mede o grau de correlação linear entre as classificações de usuários ou itens [Grcar 2004], sendo definida pela seguinte fórmula:

$$similaridade(A, B) = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2}\sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2}}$$

em que x_i e y_i representam os valores observados, enquanto $\bar{x}$ e $\bar{y}$ correspondem às médias dos vetores analisados.

3.4.5. Validação do modelo

Por fim, a qualidade das abordagens foi avaliada por meio das métricas *RMSE* e *MAE*, além das métricas de precisão, *recall*, *MRR* e *hit rate* amplamente utilizadas na avaliação de sistemas de recomendação [Su and Khoshgoftaar 2009, Chen et al. 2021].

As métricas RMSE e MAE foram empregadas para mensurar a qualidade das predições realizadas pelos modelos, avaliando o erro entre os valores previstos e os valores reais observados. Já as métricas de precisão e *recall* foram utilizadas para analisar a qualidade das recomendações geradas, considerando tanto a relevância dos itens recomendados quanto a capacidade do sistema de recuperar itens relevantes para os usuários [Chen et al. 2021]. A seguir, são apresentadas as definições das métricas [Chen et al. 2021] utilizadas na avaliação dos modelos:

- **RMSE (*Root Mean Squared Error*)**
  Mede a raiz do erro quadrático médio entre os valores reais e os valores preditos pelo sistema de recomendação. Quanto menor o valor do RMSE, melhor a capacidade preditiva do modelo.

$$RMSE = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(r_i - \hat{r}_i)^2} \tag{1}$$

  onde r_i representa o valor real, $\hat{r}_i$ o valor predito e N o número total de predições.
- **MAE (*Mean Absolute Error*)**
  Mede o erro absoluto médio entre os valores reais e os valores previstos pelo modelo, sendo menos sensível a grandes erros quando comparado ao RMSE.

$$MAE = \frac{1}{N}\sum_{i=1}^{N}|r_i - \hat{r}_i| \tag{2}$$

  onde r_i corresponde ao valor real, $\hat{r}_i$ ao valor predito e N ao total de predições.
- **Matriz de Confusão**
  No contexto deste trabalho, um *True Positive (TP)* corresponde aos itens recomendados que foram considerados relevantes para o usuário. Já um *False Positive (FP)* representa os itens recomendados que não foram considerados relevantes. Assim, a soma de TP e FP corresponde ao total de itens recomendados pelo sistema.
  Por outro lado, um *False Negative (FN)* corresponde aos itens relevantes que não foram recomendados ao usuário, enquanto um *True Negative (TN)* representa os

itens não recomendados que realmente não eram relevantes. Assim, a soma de TP e FN representa o conjunto total de itens relevantes existentes para o usuário.

- **Precisão**
  Avalia a proporção de itens recomendados que são realmente relevantes.

$$Precision = \frac{|TP|}{|TP + FP|} \tag{3}$$

  Valores maiores indicam melhor qualidade das recomendações.
- ***Recall***
  Mede a capacidade do sistema em recuperar itens relevantes dentre todos os itens relevantes disponíveis.

$$Recall = \frac{|TP|}{|TP + FN|} \tag{4}$$

  Valores elevados de *recall* indicam maior cobertura de itens relevantes pelo sistema de recomendação.
- ***MRR* (*Mean Reciprocal Rank*)**
  Mede a posição do primeiro item relevante na lista de recomendações, considerando o inverso do seu ranking.

$$MRR = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{rank_i} \tag{5}$$

  em que $rank_i$ corresponde à posição do primeiro item relevante para o usuário i.
  Valores elevados de *MRR* indicam que itens relevantes aparecem nas primeiras posições das listas de recomendação.
- ***Hit Rate***
  Mede a proporção de casos em que um item relevante aparece na lista de recomendações.

$$Hit\ Rate = \frac{N_{hits}}{N_{rec}} \tag{6}$$

  em que N_{hits} representa o número de recomendações que contêm ao menos um item relevante, e N_{rec} corresponde ao total de recomendações realizadas.
  Valores elevados de *hit rate* indicam que o sistema consegue incluir ao menos um item relevante entre os recomendados.

3.4.6. Recomendações

Após o cálculo das similaridades, o modelo tornou-se apto para realizar recomendações. Dessa forma, diferentes estratégias de recomendação foram implementadas, entre elas:

- Recomendação de itens semelhantes a um item de referência, com base na similaridade entre itens;
- Recomendação de itens para um usuário a partir da similaridade com outro usuário;

- Recomendação de itens utilizando múltiplos usuários similares, considerando a contribuição conjunta de usuários com perfis semelhantes;
- Recomendação híbrida, realizada a partir da combinação das predições obtidas pelos modelos baseados em itens e em usuários, utilizando a média ponderada entre ambos os métodos para definir os itens de maior relevância prevista.

Além disso, com base na validação, a melhor abordagem do campo *item* foi usada para construir tabelas de atributos. Foram analisados aspectos como missões, dificuldade, interação com NPCs, progresso e masmorras. Isso permitiu avaliar a influência das quatro facetas e gerar recomendações mais segmentadas.

Com isso, a recomendação foi realizada da seguinte forma: inicialmente, com base no campo *item*; em seguida, pelas tabelas específicas, considerando a média dos melhores itens; depois, pelos níveis existentes com base nas métricas; e, por fim, pela sugestão de uma masmorra com novas configurações.

Referências

Balda, H. D. F. (2020). Improvement of player experience through dynamic difficulty adjustment using behavioral patterns and machine learning. Diss. (graduação), Tokyo University of Technology.

Carneiro, N., Souza, K., Sidarta, I., Pereira, G., Mendonça, G., and Darin, T. (2021). To each their own (type): A systematic mapping study on player's motivations, behavior, and personality characteristics. In *Proceedings of the XX Brazilian Symposium on Human Factors in Computing Systems*, IHC '21, New York, NY, USA. Association for Computing Machinery.

Chanel, G. and Lopes, P. (2020). User evaluation of affective dynamic difficulty adjustment based on physiological deep learning. In *Augmented Cognition. Theoretical and Technological Approaches*, pages 3–23, Cham. Springer International Publishing.

Chen, Y.-C., Hui, L., and Thaipisutikul, T. (2021). A collaborative filtering recommendation system with dynamic time decay. *J. Supercomput.*, 77(1):244–262.

Chrysafiadi, K., Kamitsios, M., and Virvou, M. (2023). Fuzzy-based dynamic difficulty adjustment of an educational 3d-game. *Multimedia Tools and Applications*, 82(18):27525–27549.

de Lima, E. S., Silva, B. M., and Galam, G. T. (2022). Adaptive virtual reality horror games based on machine learning and player modeling. *Entertainment Computing*, 43:100515.

de Oliveira, D. S. (2019). Sistema de recomendação baseado em filtragem colaborativa em uma base de dados de feedback implícito. Master's thesis, Centro de Informática, Universidade Federal de Pernambuco, Recife. Trabalho de Graduação (Bacharel em Ciência da Computação).

Global Growth Insights (2024). Video game market size, share, growth, and industry analysis, by types (kids, adults), applications (action, adventure and role playing, arcade, strategy, simulation, driving, other), and regional insights and forecast to 2035. `https://www.globalgrowthinsights.com/pt/market-reports/video-game-market-107798`. Acesso em: 16 mar. 2026.

Grcar, M. (2004). User profiling: Collaborative filtering. In *Proceedings of SIKDD 2004 at Multiconference IS*, pages 75–78.

Hannon, J., Bennett, M., and Smyth, B. (2010). Recommending twitter users to follow using content and collaborative filtering approaches. In *Proceedings of the Fourth ACM Conference on Recommender Systems*, RecSys '10, page 199–206, New York, NY, USA. Association for Computing Machinery.

Koren, Y., Rendle, S., and Bell, R. (2022). *Advances in Collaborative Filtering*, pages 91–142. Springer US, New York, NY.

Liapis, A., Yannakakis, G. N., Nelson, M. J., Preuss, M., and Bidarra, R. (2019). Orchestrating game generation. *IEEE Transactions on Games*, 11(1):48–68.

Liapis, A., Yannakakis, G. N., and Togelius, J. (2014). Computational game creativity. In *Proceedings of the fifth International Conference on Computational Creativity*.

Martins, B. d. H. (2021). Assessing game player profiles through agent-based simulation.

Pereira, L., Teoi, Y., and Toledo, C. (2024). Towards evaluating a procedural content orchestrator gameplay data to differentiate user profiles. In *Anais do III Workshop sobre Interação e Pesquisa de Usuários no Desenvolvimento de Jogos*, pages 75–86, Porto Alegre, RS, Brasil. SBC.

Pereira, L., Viana, B., and Toledo, C. (2022). A system for orchestrating multiple procedurally generated content for different player profiles. *IEEE Transactions on Games*, PP:1–11.

Pereira, L. T., Teoi, T. Y., and Toledo, C. F. M. (2025). Evaluating a procedural content orchestrator gameplay data and classifying user profiles. *Journal on Interactive Systems*, 16(1):490–504.

Ricci, F., Rokach, L., and Shapira, B. (2010). *Recommender Systems Handbook*, volume 1-35, pages 1–35.

Rosa, M. P., Castanho, C., Silva, T., Sarmet, M., and Jacobi, R. (2023). *Dynamic Difficulty Adjustment by Performance and Player Profile in Platform Game*, pages 3–16.

Sanker, A. P. (2025). Filtragem colaborativa: Seu guia para recomendações mais inteligentes. DataCamp. Acesso em: 14 de abril de 2026.

Schrader, C. (2022). *Serious Games and Game-Based Learning*, pages 1–14. Springer Singapore, Singapore.

Su, X. and Khoshgoftaar, T. M. (2009). A survey of collaborative filtering techniques. *Advances in Artificial Intelligence*, 2009(1):421425.

Teoi, T., Pereira, L., and Toledo, C. (2024). Towards adapting a content orchestrator to a different gamegenre: Generating levels, rules, and narrative for diverse player profiles from a top-down adventure to a 2d platformer. In *Anais do XXIII Simpósio Brasileiro de Jogos e Entretenimento Digital*, pages 396–415, Porto Alegre, RS, Brasil. SBC.

Yee, N. and Ducheneaut, N. (2018). Gamer motivation profiling: uses and applications. In Drachen, A., Mirza-Babaei, P., and Nacke, L., editors, *Games User Research*. Oxford University Press.