Filtragem Colaborativa para Perfilamento de Jogadores em Jogos Digitais

Pedro G. Gonçalves

Instituto de Geociências e Ciências Exatas – Universidade Estadual Paulista (UNESP)
Rio Claro – SP – Brazil

pedro.g.goncalves@unesp.br

Abstract. *One of the main challenges in the digital games industry is understanding players' preferences in order to provide experiences that promote high levels of immersion and satisfaction. In this work, an approach for content recommendation based on player profiles was developed. To this end, different collaborative filtering approaches were implemented and compared. The results obtained enabled the identification of the model with the best performance, demonstrating its suitability for personalizing the player experience.*

Resumo. *Um dos principais desafios da indústria de jogos digitais é compreender as preferências dos jogadores a fim de oferecer experiências que promovam elevados níveis de imersão e satisfação. Neste trabalho, foi desenvolvida uma abordagem para recomendação de conteúdo com base no perfil dos jogadores. Para isso, foram implementadas e comparadas diferentes abordagens de filtragem colaborativa. Os resultados obtidos possibilitaram a identificação do modelo com melhor desempenho, evidenciando sua adequação para a personalização da experiência do jogador.*

1. Introdução

A indústria de jogos digitais, que projeta expandir de US$ 25,5 bilhões para US$ 37,74 bilhões até 2035 [Global Growth Insights 2024], apresenta o desafio de atender a públicos diversificados. Para isso, compreender o comportamento e as preferências do jogador torna-se fundamental para produzir conteúdos que aumentem sua imersão e satisfação [Martins 2021, Balda 2020].

Assim, diversas técnicas são utilizadas, como heurísticas, lógica *fuzzy*, filtragem colaborativa e algoritmos de Aprendizado de Máquina (AM) e Aprendizado Profundo (AP) [Rosa et al. 2023, Hannon et al. 2010, Chrysafiadi et al. 2023, Chanel and Lopes 2020, de Lima et al. 2022, Sanker 2025], com o objetivo de promover a personalização, que pode ser realizada por meio de técnicas de recomendação baseadas em dados de comportamento, desempenho ou avaliação do jogador [Sanker 2025, Balda 2020].

Dentre essas técnicas, a filtragem colaborativa contribui ao identificar jogadores semelhantes com base em seus padrões de interação, possibilitando a inferência de preferências e comportamentos de um jogador a partir dos dados de seus vizinhos mais próximos. [Sanker 2025, Grcar 2004].

Dessa forma, padrões observados em grupos de jogadores com perfis semelhantes podem ser utilizados para estimar características de novos jogadores, mesmo na

ausência de dados completos. Esse processo viabiliza a associação desses jogadores a perfis representativos, possibilitando, assim, a recomendação adequada de conteúdo [Sanker 2025, Chen et al. 2021].

Com base nisso, este projeto investigou abordagens para recomendação de conteúdo utilizando a filtragem colaborativa como mecanismo de personalização. Para isso, foi utilizada uma base de dados composta por informações de jogadores e partidas, coletada no contexto *Overlord*, um orquestrador de Geração Procedural de Conteúdo [Pereira et al. 2024b] e disponibilizada no trabalho [Pereira et al. 2024a].

Essa base é composta por aproximadamente 119 instâncias de gameplay (registros de sessões de jogo), posteriormente expandida para mais de 1000 instâncias por meio de técnicas estatísticas de aumento de dados (*data augmentation*), conforme metodologia validada na literatura [Pereira et al. 2025]. Esse procedimento visou mitigar os efeitos do tamanho reduzido da amostra original e permitir uma avaliação mais robusta dos modelos. Ela reúne dados relacionados aos níveis gerados (masmorras com quebra-cabeças e posicionamento de inimigos), narrativa (missões) e regras (atributos e mecânicas dos inimigos), permitindo a extração de padrões de comportamento e desempenho.

A partir desses dados, buscou-se identificar e agrupar jogadores em diferentes perfis de jogabilidade, possibilitando a recomendação de níveis mais adequados, bem como a indicação separada de parâmetros como dificuldade de inimigos e preferências por missões.

Com os dados estruturados, foram implementados e comparados três modelos: a filtragem baseada em item, na qual é considerada a avaliação do nível pelo jogador; a filtragem baseada no usuário, a partir de dados de seu comportamento na partida; e um modelo misto de ambos [Hannon et al. 2010, Su and Khoshgoftaar 2009, Koren et al. 2022]. Para isso, foram utilizadas as medidas de similaridade de cosseno e correlação de Pearson para quantificar a semelhança entre usuários [Sanker 2025].

A avaliação da filtragem colaborativa foi realizada por meio de métricas de predição RMSE e MAE, comparando as notas previstas com as notas reais no conjunto de teste. Para isso, adotou-se a divisão treino-teste, utilizando o conjunto de treino para aprender os padrões de similaridade entre jogadores e itens, enquanto o conjunto de teste foi utilizado para validação das predições. Adicionalmente, foram utilizadas métricas de precisão e *recall* para avaliar a qualidade das recomendações geradas [Su and Khoshgoftaar 2009, Chen et al. 2021].

As principais contribuições deste trabalho são: (i) fornecer, por meio dos resultados obtidos, uma análise comparativa fundamentada dos pontos fortes e das limitações das abordagens investigadas, contribuindo para a área de jogos sérios e entretenimento [Schrader 2022]; (ii) oferecer subsídios teóricos e práticos para o desenvolvimento de sistemas de recomendação e adaptação mais robustos em jogos digitais; e (iii) contribuir para a área de IA ao investigar a aplicação de filtragem colaborativa na modelagem do comportamento de jogadores, avaliando sua capacidade de perfilamento e recomendação em ambientes interativos.

O artigo está organizado da seguinte forma: a Seção 2 apresenta os trabalhos relacionados sobre a adaptação de jogos; a Seção 3 descreve a metodologia; a Seção 4 discute os resultados; e a Seção 5 apresenta as conclusões.

Referências

Balda, H. D. F. (2020). Improvement of player experience through dynamic difficulty adjustment using behavioral patterns and machine learning. Diss. (graduação), Tokyo University of Technology.

Chanel, G. and Lopes, P. (2020). User evaluation of affective dynamic difficulty adjustment based on physiological deep learning. In *Augmented Cognition. Theoretical and Technological Approaches*, pages 3–23, Cham. Springer International Publishing.

Chen, Y.-C., Hui, L., and Thaipisutikul, T. (2021). A collaborative filtering recommendation system with dynamic time decay. *J. Supercomput.*, 77(1):244–262.

Chrysafiadi, K., Kamitsios, M., and Virvou, M. (2023). Fuzzy-based dynamic difficulty adjustment of an educational 3d-game. *Multimedia Tools and Applications*, 82(18):27525–27549.

de Lima, E. S., Silva, B. M., and Galam, G. T. (2022). Adaptive virtual reality horror games based on machine learning and player modeling. *Entertainment Computing*, 43:100515.

Global Growth Insights (2024). Video game market size, share, growth, and industry analysis, by types (kids, adults), applications (action, adventure and role playing, arcade, strategy, simulation, driving, other), and regional insights and forecast to 2035. `https://www.globalgrowthinsights.com/pt/market-reports/video-game-market-107798`. Acesso em: 16 mar. 2026.

Grcar, M. (2004). User profiling: Collaborative filtering. In *Proceedings of SIKDD 2004 at Multiconference IS*, pages 75–78.

Hannon, J., Bennett, M., and Smyth, B. (2010). Recommending twitter users to follow using content and collaborative filtering approaches. In *Proceedings of the Fourth ACM Conference on Recommender Systems*, RecSys '10, page 199–206, New York, NY, USA. Association for Computing Machinery.

Koren, Y., Rendle, S., and Bell, R. (2022). *Advances in Collaborative Filtering*, pages 91–142. Springer US, New York, NY.

Martins, B. d. H. (2021). Assessing game player profiles through agent-based simulation.

Pereira, L., Teoi, Y., and Toledo, C. (2024a). Towards evaluating a procedural content orchestrator gameplay data to differentiate user profiles. In *Anais do III Workshop sobre Interação e Pesquisa de Usuários no Desenvolvimento de Jogos*, pages 75–86, Porto Alegre, RS, Brasil. SBC.

Pereira, L. T., Teoi, T. Y., and Toledo, C. F. M. (2025). Evaluating a procedural content orchestrator gameplay data and classifying user profiles. *Journal on Interactive Systems*, 16(1):490–504.

Pereira, L. T., Viana, B. M. F., and Toledo, C. F. M. (2024b). A system for orchestrating multiple procedurally generated content for different player profiles. *IEEE Transactions on Games*, 16(1):64–74.

Rosa, M. P., Castanho, C., Silva, T., Sarmet, M., and Jacobi, R. (2023). *Dynamic Difficulty Adjustment by Performance and Player Profile in Platform Game*, pages 3–16.

Sanker, A. P. (2025). Filtragem colaborativa: Seu guia para recomendações mais inteligentes. DataCamp. Acesso em: 14 de abril de 2026.

Schrader, C. (2022). *Serious Games and Game-Based Learning*, pages 1–14. Springer Singapore, Singapore.

Su, X. and Khoshgoftaar, T. M. (2009). A survey of collaborative filtering techniques. *Advances in Artificial Intelligence*, 2009(1):421425.